

分类号 CLC

U D C UDC

编号 20250328

密级 公开



南方科技大学

SOUTHERN UNIVERSITY OF SCIENCE AND TECHNOLOGY

本科生毕业设计（论文）

题目：面向单源域眼底图像的

频带重要性感知血管分割方法

姓名：王稟钦

学号：12210723

院系：计算机科学与工程系

专业：计算机科学与技术

指导教师：刘江 讲席教授

2026 年 05 月 28 日

诚信承诺书

1. 本人郑重承诺所呈交的毕业设计（论文），是在导师的指导下，独立进行研究工作所取得的成果，所有数据、图片资料均真实可靠。

2. 除文中已经注明引用的内容外，本论文不包含任何其他人或集体已经发表或撰写过的作品或成果。对本论文的研究作出重要贡献的个人和集体，均已在文中以明确的方式标明。

3. 本人承诺在毕业论文（设计）选题和研究内容过程中没有抄袭他人研究成果和伪造相关数据等行为。

4. 在毕业论文（设计）中对侵犯任何方面知识产权的行为，由本人承担相应的法律责任。

作者签名：

_____年____月____日

面向单源域眼底图像的 频带重要性感知血管分割方法

王稟钦

(计算机科学与工程系 指导教师：刘江 讲席教授)

[摘要]：单源域泛化（SDG）关注在只有一个源域可用的条件下训练模型，使其在未见目标域中仍保持稳定表现。在视网膜血管分割任务中，不同数据集之间常存在采集设备、病种构成、图像噪声和颜色分布等差异，这些因素会造成明显的域偏移。现有研究已表明域偏移会削弱分割模型的跨域性能，但其与频域特征变化之间的关系仍缺少充分分析。本文认为，数据集差异会在频谱分布中体现出来，并可能促使模型记忆源域特有的频率模式。针对这一问题，本文提出频带重要性感知随机频率滤波单源域泛化方法（BIRF-SDG）。该方法通过频带评分机制估计不同频率带对结构保持和分割性能的贡献，并优先保护与血管分割密切相关的关键频带；同时，引入加权随机频带滤波作为增强策略，在扩大训练分布的同时降低关键结构受损的风险。跨域眼底数据集上的对比实验和消融实验表明，BIRF-SDG 能够提升模型在未见目标域上的血管分割性能，并缓解域偏移带来的影响。

[关键词]：视网膜图像；血管分割；单源域泛化；频率丢失

[ABSTRACT]: Single-source domain generalization (SDG) is used to improve model’s performance on unseen target domains by utilizing data from one source domain, with a primary emphasis on alleviating the impact of domain shifts. In the context of retinal vessel segmentation, domain shifts often arise due to variations in datasets composition, such as discrepancies in disease prevalence and imaging noise levels. Despite their significance, the underlying mechanisms through which these shifts impact model performance remain insufficiently explored. In this paper, we hypothesize that dataset variations are reflected in the distributional differences of frequency-domain features, which can cause models to overfit to specific patterns within the source dataset. To address the problem, this paper proposes a novel SDG method, denoted as Band Importance Aware Random Frequency Filter based Single-source Domain Generalization (BIRF-SDG). This framework incorporates a band scoring mechanism designed to identify and preserve frequency bands that are critical for segmentation tasks, thereby preventing the loss of essential information in subsequent processes. Furthermore, we propose a random band filtering strategy as a data augmentation technique to improve the model’s generalization across various domains. Extensive comparative experiments and ablation analyses on cross-domain retinal image datasets confirm that our method attains state-of-the-art performance, effectively addressing the challenges associated with domain shift in retinal vessel segmentation.

[Key words]: Retinal Image; Vessel Segmentation; Single-source Domain Generalization; Frequency Dropout

目录

1. 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.3 研究内容与贡献	2
1.4 论文组织结构	3
2. 相关工作	3
2.1 视网膜血管分割	3
2.2 域泛化方法	4
2.3 频域分析方法	5
2.4 本章小结	7
3. 研究方法	7
3.1 问题定义	7
3.2 方法概述	8
3.3 频域增强	9
3.3.1 傅里叶变换	9
3.3.2 频带划分与掩码	9
3.4 频带重要性感知随机滤波	10
3.4.1 结构评分与分割评分	10
3.4.2 随机频带滤波	11
3.5 分割网络整体结构	12
3.6 算法流程	13
4. 实验	14
4.1 实验设置	14
4.1.1 数据集	14
4.1.2 实现细节	16

4.1.3 评估指标	16
4.2 对比实验	16
4.2.1 对比方法	16
4.2.2 定量结果	17
4.2.3 定性结果	17
4.2.4 训练过程分析	18
4.3 消融实验	18
4.3.1 实验设计	18
4.3.2 消融结果	19
4.4 讨论	19
4.4.1 方法优势	19
4.4.2 局限性	19
4.4.3 未来改进方向	20
5. 结论	20
参考文献	21
致谢	27

1. 绪论

1.1 研究背景与意义

眼底血管的走向、宽度和分支形态与多类眼科疾病及全身性疾病相关，因此自动血管分割是眼底图像分析中的基础环节^[1,2]。可靠的血管掩膜能够为糖尿病视网膜病变、青光眼和高血压相关眼底改变等疾病的观察提供结构依据。然而，眼底图像常受医院来源、拍摄设备和采集流程影响，在亮度、对比度、颜色分布和噪声水平上呈现差异，导致分割模型在临床真实场景中容易出现性能波动。

该任务的另一个难点来自医学数据本身。血管标注通常需要专业人员逐像素完成，耗时长、成本高，并且不同机构之间的数据共享还受到隐私保护和伦理审批的限制。因此，研究者在训练模型时往往只能获得规模有限、来源单一的标注数据。如果模型过度依赖源数据集中的成像风格或局部纹理，它在其他医院或其他采集设备上的表现就可能明显下降。

训练数据和测试数据分布不一致时，模型面临的问题通常称为域偏移（domain shift）^[3]。域泛化（domain generalization）希望在不使用目标域样本的前提下，从源域数据中学习可迁移的表示^[4]。进一步地，单源域泛化（single-source domain generalization, SDG）只允许训练数据来自一个源域^[5]，这一设定更贴近医学图像标注数据有限的情况，但也放大了源域偏差带来的风险。因此，本文关注如何仅依赖单一标注眼底数据集，训练出能够适应未见目标域的血管分割模型。

提高泛化性能时，数据增强是最常用的训练策略之一。现有空间域增强通常采用裁剪、旋转、缩放和颜色扰动等操作^[6]，但这些变化不一定能覆盖不同眼底数据集之间的成像风格差别。频域增强则直接处理图像频谱，为模拟风格和结构变化提供了另一种途径。已有研究通过振幅谱交换或频谱扰动扩展训练样本^[7,8]，但这类方法往往没有区分不同频率成分对分割任务的重要程度：关键频带被过度扰动时，血管边界和细小分支可能受损；扰动过弱时，又难以形成有效的跨域变化。因此，本文尝试设计一种频带重要性感知的选择性增强方法。

1.2 国内外研究现状

域泛化研究的核心目标，是让模型在训练分布之外仍能保持稳定预测能力。早期工作通常默认训练阶段可以获得多个源域，并利用跨域特征对齐、对抗学习或元学习提取更稳定的表示。然而在医学图像场景中，多机构数据获取困难，数据格式和标注标准也可能不一致，因此只依赖一个源域的 SDG 逐渐成为更符合实际部署条件的研究方向。现有 SDG 方法大致可分为数据增强、特征约束和正则化三类。

数据增强方法通过扩展训练样本的变化范围，削弱模型对源域外观模式的依赖。除常规几何变换和颜色变换外，Mixup、CutMix 和 AutoAugment 等方法也可构造更复杂的训练样本。特征约束方法侧重于表示学习，通常借助对抗训练、元学习或特征解耦提升特征跨域稳定性。正则化方法则利用 Dropout、Batch Normalization 和 Label Smoothing 等机制减轻过拟合，使模型在未知数据上更加稳健。

近年来，频域建模为 SDG 提供了新的切入点。傅里叶变换能够把图像表示为不同频率成分的组合，其中振幅谱更容易反映成像风格，相位谱则与结构布局联系更紧密。FDA 通过替换振幅谱生成目标域风格样本^[7]，振幅扰动方法通过随机改变频谱扩大训练分布^[8]。这些方法能够增加样本多样性，但通常没有显式判断哪些频带承载血管结构，也难以控制增强对分割结果的影响。基于这一问题，本文从频带重要性出发，在结构保持和跨域变化之间寻求平衡。

1.3 研究内容与贡献

针对上述问题，本文提出一种基于频带重要性感知的随机频率滤波方法 BIRF-SDG。该方法通过评估不同频带对结构保留和分割性能的影响，选择性地对非关键频带进行随机滤波，从而在增强数据多样性的同时降低关键血管结构被破坏的风险。

本文的主要贡献包括四点。第一，提出面向视网膜血管分割的单源域泛化框架，从频域角度缓解数据集间成像差异带来的域偏移。第二，设计频带重要性评分机制，分别衡量频带对结构信息和分割结果的影响，从而识别需要保护的关键频带。第三，提出加权随机频带滤波策略，使增强过程集中作用于对结构影响较小的频率区域，降低过度增强导致性能下降的可能性。第四，在多个跨域眼底血管分割数据集上进行对比实验和消融分析，验证所提方法在未见目标域上的泛化效果。

1.4 论文组织结构


后续章节安排如下。第二章回顾视网膜血管分割、域泛化和频域分析方面的相关研究。第三章介绍 BIRF-SDG 的整体设计，并说明频域增强、频带重要性感知随机滤波和多流分割网络等关键模块。第四章给出实验设置、对比实验和消融实验结果。第五章总结本文工作，并讨论可能的改进方向。

2. 相关工作


2.1 视网膜血管分割

视网膜血管分割需要从眼底图像中提取血管像素，并将其与背景区域分离，为病变分析、血管形态测量和辅助诊断提供基础结果^[1,9]。传统方法通常依赖人工设计的图像处理算子，包括边缘检测、形态学处理、匹配滤波和阈值分割等。随着深度学习的发展，神经网络逐渐成为医学图像分割的主要技术路线，并在特征表达和复杂模式建模方面表现出更强能力^[10,11]。

在深度学习分割模型中，编码器-解码器结构应用最为广泛。U-Net 利用跳跃连接把浅层细节与深层语义结合起来，较适合处理血管这类细长、分支多且边界不规则的目标。Attention U-Net^[12] 在跳跃连接中加入注意力门控，以抑制无关背景并突出目标区域；DenseNet^[13] 和 ResNet^[14] 则通过密集连接或残差连接提升深层特征表达能力。此外，SegNet^[15]、DeepLab^[16]、PSPNet^[17] 以及采用空洞卷积的编码器-解码器结构^[18] 也被引入医学图像分割任务。Squeeze-and-Excitation 网络^[19] 与 ECA-Net^[20] 等通道注意力方法能够加强特征选择能力。不过，上述模型通常建立在训练集和测试集分布相近的假设上，当数据来自不同机构或设备时，性能下降仍较常见^[6]。



(a) U-Net



(b) Attention U-Net

图1 典型编码器-解码器血管分割网络示意图。U-Net通过跳跃连接融合多尺度特征，Attention U-Net进一步在跳跃连接中加入注意力门控以突出目标区域。

图1展示了U-Net及Attention U-Net的基本结构。编码器逐步压缩分辨率并提取语义信息，解码器通过上采样恢复像素级输出；跳跃连接用于补充边缘和细小分支等局部细节，注意力门控则进一步筛选与血管区域相关的特征。

2.2 域泛化方法

多源域泛化 (Multi-source Domain Generalization) 默认训练阶段能够获得多个来源的数据，并通过这些来源学习对域变化更稳定的特征^[21,22]。常见技术路线包括域对抗训练、元学习和特征解耦。域对抗训练利用域判别器约束特征表示，使特征提取器生成更难区分来源的特征；生成对抗网络 (GAN)^[23] 和图像到图像转换方法^[24] 则可模拟不同域之间的外观变化。元学习方法通过构造虚拟训练域和测试域，让模型学习在域变化下快速适应；特征解耦方法试图把域相关因素与任务相关因素分开。尽管这些方法具有一定效果，医学数据跨机构收集仍受到隐私、伦理和标注一致性的限制，因此多源设定在实际应用中并不总是可行。

图2概括了域对抗训练流程。图像先经过特征提取器得到中间表示，随后由标签预测器完成目标任务，并由域判别器判断特征来源。梯度反转层使特征提取器在优化主任务的同时削弱域可辨识信息，从而获得更接近域不变的表示。




图2 域对抗训练框架示意图。该框架包含三个主要组件：特征提取器（Feature Extractor）、标签预测器（Label Predictor）和域判别器（Domain Discriminator）。输入图像经过特征提取器得到特征表示，标签预测器基于特征进行类别预测（计算标签预测损失 L_y ），域判别器尝试区分特征来自源域还是目标域（计算域分类损失 L_d ）。通过梯度反转层（Gradient Reversal Layer），特征提取器学习到的特征既能够完成目标任务，又无法被域判别器区分来源，从而实现域不变特征学习。

单源域泛化（Single-source Domain Generalization, SDG）进一步降低了对多源数据的要求，仅使用一个源域完成训练，并希望模型在未知目标域上仍具备可用性能^[25]。现有 SDG 研究主要包括数据增强、正则化和特征扰动等方向。Mixup^[26]、CutMix^[27]、AutoAugment^[28] 以及 AugMix^[29] 通过构造更多样的训练样本提升鲁棒性^[30]。MAML^[31] 和 Reptile^[32] 从元学习角度模拟快速适应过程，联邦学习^[33] 则为隐私保护下的分布式训练提供可能。Dropout^[34]、Batch Normalization 和 Label Smoothing 等正则化技术可缓解过拟合，特征扰动和对抗训练也有助于增强模型对分布变化的稳定性^[35]。

2.3 频域分析方法

傅里叶变换可以将图像表示为不同频率成分的组合，使研究者能够从频域角度分析图像内容。一般而言，低频成分更多反映整体亮度和大尺度结构，高频成分则与边缘、纹理和局部细节相关。在跨域视觉任务中，不同数据集的风格差异常常会体现在频谱分布上，其中振幅谱与成像风格关系较强，相位谱则更接近空间结构信息。

基于频谱差异的观察，已有研究提出了多种频域增强策略。FDA（Fourier Domain Adaptation）通过交换振幅谱生成具有目标域风格的训练样本^[7,36]。傅里叶卷积网络利用快速傅里叶变换提升特征处理效率^[37]，频率通道注意力则尝试加强模型对频率特征的选择能力^[38]。Amplitude Perturbation 通过随机扰动振幅谱扩展训练分布^[8]，Frequency Dropout

则通过随机丢弃部分频率成分减少模型对特定频带的依赖^[39,40]。此外，自监督学习^[41,42]和多尺度域泛化方法^[43,44]也被用于提升跨域性能。

图 3 展示了 FD-SDG 的基本流程^[39]。该方法先将图像映射到频域，再对部分频率成分进行丢弃式增强，最后通过逆变换回到空间域并送入分割网络。该思路能够减少模型对固定频率模式的依赖，但随机丢弃并未显式区分结构关键频带和可增强频带。与之相关，CSCA 通过跨域注意力机制改善分割特征^[45]，FedDG 则在联邦学习框架下研究域泛化问题^[46]。




图 3 FD-SDG 频域增强方法示意图。该方法通过 FFT 将输入图像转换到频域，在频率域中进行随机丢弃或扰动，并通过逆 FFT 生成增强图像，再送入分割网络进行训练。

图 4 给出了频域混合增强的示意。该方法通过组合不同图像的频域信息生成风格变化更丰富的训练样本，从而提升模型对成像差异的适应能力。

总体而言，频域增强已经证明频谱扰动能够为跨域泛化提供有效信息，但现有方法对频带的选择仍不够精细。如果增强过程影响到血管边界或细小分支依赖的关键频率区域，分割结果可能受到损害；如果扰动幅度过小，又难以覆盖真实目标域中的风格变化。近期研究还从任务特定增强^[47]、注意力特征建模^[48]、多视图学习^[49]和人工智能驱动的频域适应^[50]等角度分析域偏移问题。深度学习已广泛用于医学图像分析^[51-53]，包括皮肤癌检测^[54]和胸部 X 光诊断^[55]等任务，这也说明提升模型跨域泛化能力对临床部署具有实际意义。

除卷积网络外，Transformer 也被用于视觉任务，并通过自注意力机制建模长距离依赖^[56]。Vision Transformer 将图像切分为 patch 序列，再由 Transformer 编码器学习全局表示。频域学习方法则在计算效率和泛化建模两个方面显示出潜力^[57]。与此同时，MoCo^[58]和 SimCLR^[59]等自监督方法通过对比学习获得更通用的视觉表征，为降低标注依赖和增强泛化能力提供了补充途径。




图 4 频域混合增强方法示意图。该方法在源域图像及其标注的基础上生成多种频域增强样本，并通过耦合分割网络共同优化分割结果。

2.4 本章小结

本章从视网膜血管分割、域泛化和频域分析三个方面梳理了相关研究。现有分割网络在同分布数据上通常能够取得较好效果，但在跨设备、跨机构场景下仍容易受到域偏移影响。SDG 方法试图在数据来源有限的条件下提高模型稳健性，频域增强则为模拟跨域变化提供了可行思路。现有频域方法的不足主要在于缺少对频带重要性的显式建模，因此本文进一步提出频带重要性感知的随机频率滤波方法，以实现更可控的频域增强。

3. 研究方法

3.1 问题定义

在单源域泛化（SDG）设定下，训练阶段仅提供一个带标注的源域数据集 $\mathcal{D}_s = \{(x_i, y_i)\}_{i=1}^N$ ，其中 x_i 为输入眼底图像， $y_i \in \{0, 1\}^{H \times W}$ 为对应的像素级血管标签。目标域数据集记为 $\mathcal{D}_t$ ，其标注在训练过程中不可用。该任务要求模型 f_θ 只基于源域训练，却能在分布不同的未见目标域上保持稳定分割性能。设源域和目标域的数据分布分别为

$P_s(x, y)$ 与 $P_t(x, y)$, 当二者的边缘分布满足 $P_s(x) \neq P_t(x)$ 时, 模型会受到域偏移影响。本文的优化目标可表示为:

$$\min_{\theta} \mathbb{E}_{(x, y) \sim P_t} [\mathcal{L}(f_{\theta}(x), y)] \quad (1)$$

其中 $\mathcal{L}$ 表示分割损失函数, 可采用交叉熵损失或 Dice 损失^[60]。对于前景血管像素占比较低的情况, Focal Loss^[61] 可通过降低易分类样本权重来缓解类别不平衡。

3.2 方法概述

为缓解未见域上的性能下降, 本文提出 BIRF-SDG (Band Importance Aware Random Frequency Filter based Single-source Domain Generalization) 框架。该方法认为, 不同频率带对血管结构保持和分割判别的贡献并不相同: 部分频带承载边界和细小血管等结构信息, 应在增强过程中被保护; 另一部分频带更多对应风格或非关键变化, 可以用于构造跨域扰动。

如图 5 所示, BIRF-SDG 由三个部分组成: 首先将输入图像映射到频域并划分频带; 随后分别估计各频带对结构保持和分割输出的影响; 最后根据评分结果在可扰动频带上执行加权随机滤波, 生成用于训练的增强样本。




图 5 BIRF-SDG 框架概览。BIRF 采用加权机制评估不同频率带对分割性能的贡献, 并通过随机频带滤波策略生成增强图像。多流分割架构整合这些增强输入, 通过注意力机制利用频率感知特征, 最终形成一个高效的单源域泛化框架。

3.3 频域增强

为了使模型不过度依赖源域中的固定频谱模式，本文在训练阶段引入频域扰动。与直接改变整幅图像风格不同，我们关注单个频率带被抑制后对分割结果和结构信息的影响，并据此判断哪些频带适合被增强。

3.3.1 傅里叶变换

本文利用快速傅里叶变换（Fast Fourier Transform, $\mathcal{F}$ ）将图像 x 从空间域映射到频域：

$$X = \mathcal{F}(x) \quad (2)$$

其中 X 表示复数频谱，可进一步拆分为振幅谱 $A = |X|$ 和相位谱 $P = \angle X$ 。振幅谱刻画不同频率成分的能量分布，相位谱则更多保留图像空间结构。频域操作完成后，图像可通过逆快速傅里叶变换（inverse Fast Fourier Transform, $\mathcal{F}^{-1}$ ）映射回空间域：

$$x = \mathcal{F}^{-1}(X) \quad (3)$$

3.3.2 频带划分与掩码

为衡量不同频带的重要性，本文采用选择性抑制的方式观察模型响应。具体地，我们定义频域掩码 m ，并通过逐元素乘法控制频谱中指定区域是否被保留：

$$X_{\text{filtered}} = X \cdot m \quad (4)$$

其中 $\cdot$ 表示逐元素乘法。为便于描述，掩码被写成关于半径 r 的一维函数， r 表示频率位置到频谱中心的欧氏距离。当函数值为 0 时，对应频带被抑制；函数值为 1 时，该频带保持不变。本文将频谱划分为 n 个等宽频带，并依次分析每个频带被抑制后的影响：

$$m_i(r) = 1_{\frac{i}{n} \leq r < \frac{i+1}{n}} \quad (5)$$

其中 i 是 0 到 $n - 1$ 之间的整数，定义了丢弃掩码的边界， 1_c 是指示函数。

基于上述掩码操作，可以进一步区分与结构保持相关的频带集合 $\mathcal{B}_s$ 和与分割判别相关的频带集合 $\mathcal{B}_v$ 。设 $P_{s(\cdot)}$ 与 $P_{v(\cdot)}$ 分别表示结构保留判定和分割保留判定，则有：

$$\mathcal{B}_s = \{b_i \mid P_{s(m_i \cdot x)} = 1\} \quad (6)$$

$$\mathcal{B}_v = \{b_i \mid P_{v(m_i \cdot x)} = 1\} \quad (7)$$

通过这种频带级分析，增强过程不再随机作用于整个频谱，而是优先识别并保护分割任务依赖的频率区域。该思想与逆问题求解中的正则化技术具有一定相似性，即在引入扰动时限制解空间中的不稳定变化^[62]。

3.4 频带重要性感知随机滤波

眼底血管通常具有细长、分叉多和边界弱的特点，因此结构信息对分割结果尤为关键。如果随机滤波直接破坏包含边缘和分支的频带，模型可能获得更多风格变化，却失去必要的血管形态约束。为避免这一问题，本文引入高频模块评估频带对结构信息的贡献。

3.4.1 结构评分与分割评分

高频模块记为 $\mathcal{H}$ ，通过以下公式获取图像的显著结构：

$$H = \mathcal{H}(x) = x - g(x; \sigma) \quad (8)$$

其中 $g(x; \sigma)$ 表示标准差为 σ 的高斯平滑滤波器。原图与平滑结果相减后得到的 H 会突出边缘、细小纹理和局部结构，这些信息对血管边界定位较为关键。

若抑制某一频带后高频结构发生明显变化，则说明该频带对结构保持较为重要。本文用结构评分 s_s 描述这种影响^[63]，其计算方式为比较原始图像与滤波图像的高频成分差异：

$$s_s(b_i) = \sum |\mathcal{H}(x) - \mathcal{H}(m_i \cdot x)| \quad (9)$$

其中 x 是原始图像， b_i 表示第 i 个频带， m_i 是对应的掩码。评分越高，表示该频带对结构保留越重要。

除了结构差异外，本文还直接考察频带抑制对分割输出的影响。若移除某一频带后预测结果变化较小，则该频带更适合作为增强对象。对应的分割评分记为 s_v ：

$$s_v(b_i) = \sum |f(x) - f(m_i \cdot x)| \quad (10)$$

其中 f 表示分割网络的前向传播过程。评分越低，表示该频带对分割越不重要，可以进行增强。

综合上述两类信息，最终评分 s 定义为：

$$s(b_i) = \alpha \cdot s_s(b_i) + s_v(b_i) \quad (11)$$

其中 α 控制结构评分在总评分中的权重，默认取 1。该设计使结构保持和分割稳定性共同影响频带排序。根据评分结果，可得到结构关键频带 $\mathcal{B}_s = \{b_i \mid s_s(b_i) > \text{mean}(s_s)\}$ 以及分割关键频带 $\mathcal{B}_v = \{b_i \mid s_v(b_i) < \text{mean}(s_v)\}$ 。

3.4.2 随机频带滤波

得到频带评分后，滤波过程仍需避免误删关键结构信息。因此，本文将可扰动范围限制在结构评分较低的频带中，并在该集合内进行随机采样。可丢弃频带集合 D 定义为：

$$D = \{b_i \mid s_s(b_i) < \text{mean}(s_s)\} \quad (12)$$

随后在集合 D 中生成随机掩码，并用重建后的增强图像参与训练：

$$x_{\text{aug}} = \mathcal{F}^{-1}(X \cdot m_D) \quad (13)$$

其中 m_D 表示由可丢弃频带生成的随机掩码。其采样概率由分割评分决定：

$$p(b_i) = \text{softmax}(-s_v(b_i)) \quad (14)$$

因此，对分割输出影响较小的频带更容易被滤波，而对结果敏感的频带会以更高概率被保留。




图6 随机频带滤波模块示意图。模型根据结构评分和分割评分区分关键频带与非关键频带，并在可丢弃频带集合中随机生成滤波掩码，最终重建增强图像。

3.5 分割网络整体结构

为进一步利用频域增强带来的结构信息，本文构建了多任务分割网络。该网络在常规分割分支之外加入高频重建分支，使模型在学习血管掩膜的同时关注边界和细节恢复，从而增强对频域结构变化的感知能力。

如图 5 所示，网络包含编码器、高频解码器和分割解码器三个主要部分。编码器以 ResNet^[14] 或 DenseNet^[13] 为骨干提取多尺度特征；高频解码器借助跳跃连接接收编码器特征，并重建图像中的高频结构以强化边界信息；分割解码器负责输出血管掩膜，并通过注意力机制与高频分支进行特征交互。

两个解码器之间通过注意力机制进行信息交互，使分割分支能够利用高频分支提供的边界线索。本文采用空间和通道注意力机制（CBAM）^[48] 强化特征选择，并借助注意力建模通道和空间位置之间的关系^[64,65]。




图 7 多流分割网络结构示意图。编码器提取多尺度特征后，分别由高频解码器和分割解码器恢复边界信息与血管掩膜，并通过注意力机制进行信息交互。

图 7 展示了高频解码器、分割解码器和损失函数之间的整体关系。

设 y 为真实血管标签， $\hat{y}$ 为输入图像 x 的预测分割结果，分割分支采用交叉熵损失进行优化：

$$\mathcal{L}_{seg} = - \sum (y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})) \quad (15)$$

高频分支则通过约束解码结果与高频成分之间的差异来学习边界特征：

$$\mathcal{L}_{\text{bdr}} = \sum |\mathcal{H}(x) - \text{HFDecoder}(x)| \quad (16)$$

最终训练目标由分割损失和边界损失共同构成：

$$\mathcal{L} = \mathcal{L}_{\text{seg}} + \beta \cdot \mathcal{L}_{\text{bdr}} \quad (17)$$

其中 β 用于调节边界损失在总目标中的权重，默认取 1。

训练过程分为预热和增强两个阶段。前 20 个 epoch 仅使用原始图像训练分割网络，使模型先形成稳定的基础分割能力；随后 30 个 epoch 加入频带评分和随机滤波增强。学习率初始设为 1×10^{-4} ，并采用余弦退火策略逐步衰减至零。当验证集性能连续 10 个 epoch 没有提升时，训练提前终止。

3.6 算法流程

BIRF-SDG 的训练流程如算法 1 所示。整体过程先建立稳定分割模型，再根据频带评分生成增强样本，从而在扩展训练分布的同时保护关键血管结构。图 8 概括了预热阶段和增强阶段的关系。




图 8 BIRF-SDG 训练流程示意图。训练过程分为预热阶段和增强阶段：前 20 个 epoch 仅使用原始图

像训练，后 30 个 epoch 引入频带评分、随机滤波和多流网络联合优化。

首先初始化网络参数 θ 和频带评分模块。对于每个训练批次 (x, y) ，将图像转换到频域 $X = \mathcal{F}(x)$ ，计算各频带的结构评分 s_s 与分割评分 s_v ，并确定可丢弃频带集合 $D = \{b_i \mid s_s(b_i) < \text{mean}(s_s)\}$ 。随后根据 $p(b_i) = \text{softmax}(-s_v(b_i))$ 采样滤波掩码 m_D ，生成

增强图像 $x_{\text{aug}} = \mathcal{F}^{-1}(X \cdot m_D)$ 。模型前向传播得到分割结果 $\hat{y}$ 和低频重建结果 H ，再根据总损失 $\mathcal{L} = \mathcal{L}_{\text{seg}} + \beta \cdot \mathcal{L}_{\text{bdr}}$ 反向更新参数 θ 。训练完成后返回模型 f_θ 。

该流程的核心在于三点：其一，频带评分使模型能够区分结构关键频带和可扰动频带；其二，加权随机滤波限制增强作用范围，降低破坏血管结构的风险；其三，多任务学习同时约束分割结果和边界重建，提高模型对细小血管结构的敏感性。

4. 实验

4.1 实验设置

4.1.1 数据集

本章通过跨数据集眼底血管分割实验评估 BIRF-SDG 的有效性。实验重点考察模型从单一源域训练后迁移到未见目标域时的表现，并通过对比实验、消融实验和定性分析验证各模块的作用。

表 1 汇总了本文使用的数据集。DRIVE 被设为主要标注源域，共包含 40 张眼底图像，其中训练集和测试集各 20 张，原始分辨率为 584 乘以 565 像素。EyePACS 提供 35106 张未标注眼底图像，本文仅将其作为未标注补充数据及多源域基线方法的参考，不将其用于 BIRF-SDG 的监督训练。相关眼底数据集已广泛用于糖尿病视网膜病变研究^[66]。

目标域选取 IOSTAR、LES-AV 和 CHASE-DB1。IOSTAR 由扫描激光眼底镜（SLO）采集，与普通眼底相机在成像方式上存在差别；LES-AV 图像分辨率较高，能够呈现更密集的血管分支和局部细节；CHASE-DB1 主要由儿童眼底图像组成，与成人眼底数据在人群特征上不同。三个目标域覆盖设备、分辨率和受试者群体等多类变化，可用于检验模型跨域泛化能力。

实验中，所有输入图像均裁剪为 512 乘以 512 像素。为保证比较条件一致，各方法采用相同的数据划分、预处理流程和目标域测试方式。训练阶段采用 Adam 优化器^[67]，beta1 与 beta2 分别设为 0.9 和 0.999，初始学习率为 1 乘以 10 的负 4 次方，并使用余弦退火策略衰减至零。模型训练 50 个 epoch，其中前 20 个 epoch 作为预热阶段，后 30 个 epoch 引入频域增强，批次大小为 4。医学图像任务中样本规模与模型性能之间的关系仍值得进一步研究^[68]；AdamW^[69] 可通过解耦权重衰减提升训练稳定性。本文将频谱划分为 10 个

频带，并将频带评分权重 α 和边界损失权重 β 均设为 1.0，使结构评分与分割评分共同参与频带重要性估计。

表 1 实验数据集信息对比

数据集	图像数量	分辨率	成像设备	特点	用途
DRIVE	40 (20 训练/20 测试)	584×565	眼底相机	标准基准数据集，血管标注精细	源域
EyePACS	35106	多种	多种眼底相机	大规模未标注数据	未标注补充
IOSTAR	30	1024×1024	SLO 扫描激光眼底镜	与眼底相机图像特性差异大	目标域
LES-AV	22	1620×1080	高分辨率眼底相机	血管结构复杂，高分辨率	目标域
CHASE-DB1	28	999×960	儿童眼底相机	儿童眼底图像，与成人差异大	目标域

本文采用 DICE、MCC 和 IoU 评价分割性能。DICE 用于衡量预测掩膜与人工标注之间的重叠情况；MCC 将真阳性、真阴性、假阳性和假阴性同时纳入计算，适合评价类别不平衡条件下的二分类结果；IoU 则表示预测区域与标注区域交集在二者并集中的占比。设 TP、TN、FP 和 FN 分别为真阳性、真阴性、假阳性和假阴性，三种指标定义如下：

$$\text{DICE} = \frac{2 \cdot \text{TP}}{2 \cdot \text{TP} + \text{FP} + \text{FN}} \quad (18)$$

$$\text{MCC} = \frac{\text{TP} \cdot \text{TN} - \text{FP} \cdot \text{FN}}{\sqrt{(\text{TP} + \text{FP})(\text{TP} + \text{FN})(\text{TN} + \text{FP})(\text{TN} + \text{FN})}} \quad (19)$$

$$\text{IoU} = \frac{\text{TP}}{\text{TP} + \text{FP} + \text{FN}} \quad (20)$$

4.1.2 实现细节




图9 源域与未标注补充数据示例。(a) DRIVE 数据集样本，包含彩色眼底图像及两位专家标注，分辨率为 584×565 像素，使用 Canon CR5 非散瞳相机拍摄。(b) EyePACS 数据集样本，包含来自不同来源的眼底图像，分辨率和成像设备多样，通常用作多源域泛化的补充数据。两个数据集在图像质量、亮度和对比度上存在显著差异，体现了真实场景中的域偏移问题。

4.1.3 评估指标

上述指标的取值范围均为 0 到 1，数值越大说明预测结果与真实标签越一致。

4.2 对比实验

4.2.1 对比方法

对比方法涵盖频域增强、多模态分割和 SDG 等方向。FACT 通过振幅谱替换生成增强样本，FedDG 利用对比学习促进多源域频率信息共享。CSCA 将注意力机制引入多模态分割框架。GIN-IPA 采用因果启发的数据增强策略，FreeSDG 结合频域混合与边界感知学习，FD-SDG 通过频率丢弃提高模型泛化能力。与这些方法比较，可以更充分地评估 BIRF-SDG 在跨域血管分割中的表现。

4.2.2 定量结果

表 2 给出了不同方法在三个目标域上的定量结果，评价指标包括 DICE、MCC 和 IoU。

表 2 不同血管分割方法的性能比较

模型	LES-AV			IOSTAR			CHASE-DB1		
	DICE	MCC	IoU	DICE	MCC	IoU	DICE	MCC	IoU
FACT	0.696	0.670	0.534	0.513	0.477	0.345	0.602	0.573	0.431
FedDG	0.736	0.716	0.582	0.688	0.665	0.524	0.650	0.633	0.482
GIN-IPA	0.643	0.617	0.473	0.641	0.611	0.472	0.583	0.551	0.412
CSCA	0.646	0.624	0.480	0.494	0.485	0.332	0.154	0.233	0.412
FreeSDG	0.795	0.778	0.659	0.736	0.716	0.582	0.696	0.671	0.533
FD-SDG	0.754	0.735	0.605	0.743	0.722	0.591	0.707	0.683	0.547
BIRF-SDG	0.787	0.770	0.649	0.748	0.730	0.597	0.729	0.709	0.574

从结果可以看出，直接替换完整振幅谱的 FACT 在 IOSTAR 上表现较弱，DICE 仅为 0.513，说明过强的频域替换可能破坏分割所需的信息。FedDG 通过频率信息共享取得了比 FACT 更好的结果，但整体仍低于本文方法。GIN-IPA 的因果增强策略在部分数据集上存在波动，可能与增强强度较大有关。CSCA 虽然引入注意力机制，但在 CHASE-DB1 上 DICE 仅为 0.154，跨域稳定性不足。FreeSDG 在 LES-AV 上获得较高 DICE，但在其他目标域上不如 BIRF-SDG 稳定。FD-SDG 的频率丢弃策略具有一定效果，但缺少频带重要性约束，因此整体性能仍低于本文完整模型。

BIRF-SDG 在三个目标域上的综合指标均达到最优或接近最优。对于 IOSTAR 和 CHASE-DB1 这类与源域差异更明显的数据集，本文方法的提升更为突出，说明频带解耦与重要性感知随机滤波有助于增强模型在未知域中的适应能力。

4.2.3 定性结果

图 10 展示了不同方法的分割可视化结果。相较于部分基线方法，BIRF-SDG 在细小血管和血管连续性方面表现更稳定，断裂和漏检现象相对更少。对于受到光照变化、病灶干扰或图像质量下降影响的样本，本文方法仍能较好地保留血管边界。这表明频带重要性感知机制能够在增强数据变化的同时减少对关键结构的破坏。




图 10 三种未见目标数据集（IOSTAR、LES-AV、CHASE-DB1）上的血管分割结果可视化比较。每一行展示一个样本；各列依次为原始图像、CSCA、FACT、FD-SDG、FedDG、FreeSDG、GIN-IPPA、BIRF-SDG（本文方法）和真实标签（GT）的分割结果。可以看到，BIRF-SDG 在多个样本中能够更好地保持血管连续性并减少断裂。

4.2.4 训练过程分析

图 8 展示了 BIRF-SDG 的训练流程。预热阶段先让模型学习基础分割能力，增强阶段再引入频带评分和随机滤波，从而避免训练初期过强扰动影响收敛。图 6 展示了频带选择和增强图像重建过程，说明评分结果如何指导随机滤波。

4.3 消融实验

4.3.1 实验设计

为评估各模块的独立作用，本文设置了多组消融变体。基础模型仅包含常规数据增强和分割网络，不使用频域增强；“加频带加权”在基础模型中加入频带评分，但不执行随机滤波；“加随机滤波”进一步采用基于权重的频带滤波；BIRF-SDG 则为同时包含频带评分、随机滤波和低频结构建模的完整模型。

4.3.2 消融结果

表 3 给出了各消融变体的实验结果。

表 3 BIRF-SDG 消融实验结果

模型	LES-AV			IOSTAR			CHASE-DB1		
	DICE	MCC	IoU	DICE	MCC	IoU	DICE	MCC	IoU
基础模型	0.735	0.713	0.581	0.669	0.640	0.502	0.663	0.639	0.496
加频带加权	0.740	0.718	0.587	0.675	0.647	0.509	0.671	0.648	0.505
加随机滤波	0.745	0.723	0.594	0.692	0.666	0.529	0.678	0.648	0.505
BIRF-SDG	0.787	0.770	0.649	0.747	0.731	0.597	0.729	0.709	0.574

消融结果表明，频带加权机制能够带来稳定但有限的提升，例如 LES-AV 的 DICE 从 0.735 提升到 0.740，说明频带重要性评分有助于识别关键频率区域。在此基础上加入随机滤波后，LES-AV 的 DICE 进一步提升到 0.745，表明选择性频域扰动能够增加训练样本的有效变化。完整模型在三组数据上取得最优结果，尤其 LES-AV 的 DICE 提升到 0.787，说明高频结构建模对保持血管边界和细小结构具有重要作用。整体来看，三个模块单独使用时提升有限，组合后能够形成更明显的协同效果。

图 7 展示了高频成分机制在网络中的作用位置。高频解码器提供额外的边界结构约束，使分割分支更容易关注血管轮廓。类似地，Grad-CAM^[70] 等可视化方法可用于分析模型关注区域，ZFNet^[71] 则从特征可视化角度揭示卷积网络的层次化表示。

4.4 讨论

4.4.1 方法优势

BIRF-SDG 的优势可以概括为四点。第一，增强过程受频带评分约束，避免对全部频率成分进行同等强度的扰动。第二，高频结构约束有助于保留血管边界，降低细小分支在增强过程中被削弱的可能性。第三，方法不需要访问目标域数据，更适合目标域样本难以提前收集的医疗部署场景。第四，频域操作可通过快速傅里叶变换实现，额外计算开销有限，也便于与 MobileNet^[72]、EfficientNet^[73] 等轻量级骨干网络结合。

4.4.2 局限性

尽管实验结果验证了 BIRF-SDG 的有效性，该方法仍存在一些限制。当前频谱被固定划分为 10 个频带，可能无法适配所有数据集的频率分布。评分权重 α 仍需人工设置，尚未实现随训练状态自适应调整。此外，本文主要围绕视网膜血管分割设计网络和

损失函数，若迁移到其他医学图像分割任务，可能需要重新调整结构。最后，模型尚未显式估计预测不确定性，未来可结合贝叶斯深度学习方法^[74]提升可靠性。

4.4.3 未来改进方向

针对上述不足，后续研究可从以下方面改进。首先，可以设计数据驱动的频带划分策略，使频带边界根据图像频谱特性自动调整。其次，可以引入动态超参数更新机制，根据训练反馈自适应调节 α 和 β 。再次，可将该框架迁移到肿瘤分割、器官分割等医学图像任务中，以进一步检验其通用性。最后，频域增强还可与混合增强、对抗增强或自监督学习结合，以提升模型在未知域上的稳定性。

5. 结论

本研究面向视网膜血管分割中的域偏移问题，提出了频带重要性感知的单源域泛化方法 BIRF-SDG。该方法从频域角度建模图像结构与分割性能之间的关系，通过频带评分识别需要保护的关键频率区域，并利用加权随机频带滤波扩展训练分布，同时尽量保留血管边界和细小分支。本文还引入由高频解码器和分割解码器组成的多流网络，使模型在预测血管掩膜时能够利用边界结构信息。跨域实验表明，BIRF-SDG 在 LES-AV、IOSTAR 和 CHASE-DB1 等目标域上具有较好的分割性能；消融结果也说明频带评分、随机滤波和高频结构建模能够形成互补。相比依赖目标域样本或多机构数据的方法，BIRF-SDG 更适合数据共享受限、隐私要求较高的医疗场景。后续研究可进一步探索自适应频带划分、动态超参数调节以及与自监督学习相结合的方法，并将该框架扩展到 OCT、CT、MRI 等其他医学图像模态和分割任务中，以验证其稳定性和通用性。

参考文献

- [1] GULSHAN V, PENG L, CORAM M, et al. Development and validation of a deep learning algorithm for detection of diabetic retinopathy in retinal fundus photographs[J]. *jama*, 2016, 316(22): 2402-2410.
- [2] ORLANDO J I, BARBOSA BREDA J, VAN KEER K, et al. Towards a glaucoma risk index based on simulated hemodynamics from fundus images[C]//Medical Image Computing and Computer Assisted Intervention–MICCAI 2018: 21st International Conference, Granada, Spain, September 16-20, 2018, Proceedings, Part II 11. 2018: 65-73.
- [3] GANIN Y, LEMPITSKY V. Unsupervised domain adaptation by backpropagation[C]//International Conference on Machine Learning. 2015: 1180-1189.
- [4] CUGU I, MANCINI M, CHEN Y, et al. Attention consistency on visual corruptions for single-source domain generalization[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 4165-4174.
- [5] OUYANG C, BIFFI C, RUECKERT D. Causality-inspired single-source domain generalization for medical image segmentation[J]. *IEEE Transactions on Medical Imaging*, 2023, 42(4): 1095-1106.
- [6] HU S, LIAO Z, ZHANG J, et al. Domain and content adaptive convolution based multi-source domain generalization for medical image segmentation[J]. *IEEE Transactions on Medical Imaging*, 2022, 42(1): 233-244.
- [7] XU Q, ZHANG R, ZHANG Y, et al. A fourier-based framework for domain generalization[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 14383-14392.
- [8] LI H, LI H, ZHAO W, et al. Frequency-mixed single-source domain generalization for medical image segmentation[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. 2023: 127-136.
- [9] STAAL J, ABRÀMOFF M D, NIEMEIJER M, et al. Ridge-based vessel segmentation in color images of the retina[J]. *IEEE transactions on medical imaging*, 2004, 23(4): 501-509.
- [10] LITJENS G, KOOI T, BEJNORDI B E, et al. A survey on deep learning in medical image analysis[J]. *Medical Image Analysis*, 2017, 42: 60-88.
- [11] HESAMIAN M H, JIA W, HE X, et al. Deep learning techniques for medical image segmentation: Achievements and challenges[J]. *Journal of Digital Imaging*, 2019, 32: 582-596.

- [12] OKTAY O, SCHLEMPER J, FOLGOC L L, et al. Attention U-Net: Learning where to look for the pancreas[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. 2018: 304-312.
- [13] HUANG G, LIU Z, VAN DER MAATEN L, et al. Densely connected convolutional networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 4700-4708.
- [14] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770-778.
- [15] BADRINARAYANAN V, KENDALL A, CIPOLLA R. SegNet: A deep convolutional encoder-decoder architecture for image segmentation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(12): 2481-2495.
- [16] CHEN L C, PAPANDREOU G, KOKKINOS I, et al. DeepLab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected CRFs[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 40(4): 834-848.
- [17] ZHAO H, SHI J, QI X, et al. Pyramid scene parsing network[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 2881-2890.
- [18] CHEN L C, ZHU Y, PAPANDREOU G, et al. Encoder-decoder with atrous separable convolution for semantic image segmentation[C]//Proceedings of the European Conference on Computer Vision. 2018: 801-818.
- [19] HU J, SHEN L, SUN G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 7132-7141.
- [20] WANG Q, WU B, ZHU P, et al. ECA-Net: Efficient channel attention for deep convolutional neural networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 11534-11542.
- [21] DOU Q, CASTRO D Coelho de, KAMNITSAS K, et al. Domain generalization via model-agnostic learning of semantic features[C]//Advances in Neural Information Processing Systems: Vol. 32. 2019.
- [22] LI H, PAN S J, WANG S, et al. Domain generalization with adversarial feature learning[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 5400-5409.
- [23] GOODFELLOW I, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial nets[C]//Advances in Neural Information Processing Systems: Vol. 27. 2014.

- [24] ISOLA P, ZHU J Y, ZHOU T, et al. Image-to-image translation with conditional adversarial networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 1125-1134.
- [25] OUYANG C, CHEN C, LI S, et al. Causality-inspired single-source domain generalization for medical image segmentation[J]. IEEE Transactions on Medical Imaging, 2022, 42(4): 1095-1106.
- [26] ZHANG H, CISSE M, DAUPHIN Y N, et al. mixup: Beyond empirical risk minimization[C]//International Conference on Learning Representations. 2018.
- [27] YUN S, HAN D, OH S J, et al. CutMix: Regularization strategy to train strong classifiers with localizable features[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 6023-6032.
- [28] CUBUK E D, ZOPH B, MANE D, et al. AutoAugment: Learning augmentation policies from data[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2019: 113-123.
- [29] HENDRYCKS D, MU N, CUBUK E D, et al. AugMix: A simple data processing method to improve robustness and uncertainty[C]//International Conference on Learning Representations. 2020.
- [30] INOUE H. Multi-sample dropout for accelerated training and better generalization[J]. arXiv preprint arXiv:1905.09788, 2019.
- [31] FINN C, ABBEEL P, LEVINE S. Model-agnostic meta-learning for fast adaptation of deep networks[C]//International Conference on Machine Learning. 2017: 1126-1135.
- [32] NICHOL A, ACHIAM J, SCHULMAN J. On first-order meta-learning algorithms[C]//arXiv preprint arXiv:1803.02999. 2018.
- [33] MCMAHAN B, MOORE E, RAMAGE D, et al. Communication-efficient learning of deep networks from decentralized data[C]//Artificial Intelligence and Statistics. 2017: 1273-1282.
- [34] NITISH S. Dropout: a simple way to prevent neural networks from overfitting[J]. J. Mach. Learn. Res., 2014, 15: 1.
- [35] ZHANG J, DASHTBOZORG B, BEKKERS E, et al. Robust retinal vessel segmentation via locally adaptive derivative frames in orientation scores[J]. IEEE transactions on medical imaging, 2016, 35(12): 2631-2644.
- [36] YANG Y, SOATTO S. FDA: Fourier domain adaptation for semantic segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2020: 4085-4095.
- [37] CHI L, JIANG B, YE M. Fast Fourier convolution[C]//Advances in Neural Information Processing Systems: Vol. 33. 2020: 4479-4488.

- [38] QIN Z, ZHANG P, WU F, et al. FcaNet: Frequency channel attention networks[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 783-792.
- [39] LI B, LI H, ZHANG Y, et al. FD-SDG: Frequency Dropout Based Single Source Domain Generalization Framework for Retinal Vessel Segmentation[C]//International Conference on Intelligent Computing. 2024: 393-404.
- [40] LI H, LI H, CHEN J, et al. RaffeSDG: random frequency filtering enabled single-source domain generalization for medical image segmentation[J]. arXiv preprint arXiv:2405.01228, 2024.
- [41] LI H, LI H, SHU H, et al. Self-supervision boosted retinal vessel segmentation for cross-domain data[C]//2023 IEEE 20th International Symposium on Biomedical Imaging (ISBI). 2023: 1-5.
- [42] SU Z, YAO K, YANG X, et al. Rethinking data augmentation for single-source domain generalization in medical image segmentation[C]//Proceedings of the AAAI conference on artificial intelligence: Vol. 37. 2023: 2366-2374.
- [43] LI H, LIU H, FU H, et al. A generic fundus image enhancement network boosted by frequency self-supervised representation learning[J]. Medical Image Analysis, 2023, 90: 102945.
- [44] LI H, LIN Z, QIU Z, et al. Enhancing and adapting in the clinic: source-free unsupervised domain adaptation for medical image enhancement[J]. IEEE Transactions on Medical Imaging, 2023, 43(4): 1323-1336.
- [45] SHU X, WANG J, ZHANG A, et al. CSCA U-Net: A channel and space compound attention CNN for medical image segmentation[J]. Artificial Intelligence in Medicine, 2024, 150: 102800.
- [46] LIU Q, CHEN C, QIN J, et al. Feddg: Federated domain generalization on medical image segmentation via episodic learning in continuous frequency space[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 1013-1023.
- [47] ZHAO L, WANG L. Task-specific inconsistency alignment for domain adaptive object detection[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 14217-14226.
- [48] WOO S, PARK J, LEE J Y, et al. Cbam: Convolutional block attention module[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.
- [49] OU M, LI H, LIU H, et al. MVD-Net: Semantic segmentation of cataract surgery using multi-view learning[C]//2022 44th Annual International Conference of the IEEE Engineering in Medicine & Biology Society (EMBC). 2022: 5035-5038.

- [50] LI H, LI H, CHEN J, et al. Aif-sfda: Autonomous information filter-driven source-free domain adaptation for medical image segmentation[J]. arXiv preprint arXiv:2501.03074, 2025.
- [51] OWEN C G, RUDNICKA A R, NIGHTINGALE C M, et al. Retinal arteriolar tortuosity and cardiovascular risk factors in a multi-ethnic population study of 10-year-old children; the Child Heart and Health Study in England (CHASE)[J]. Arteriosclerosis, thrombosis, and vascular biology, 2011, 31(8): 1933-1938.
- [52] ZHANG W, DING X, LIU Y, et al. Slide deep reinforcement learning networks: Application for left ventricle segmentation[J]. Pattern Recognition, 2023, 141: 109667.
- [53] ZHANG W, LI S, WANG Y, et al. EEMSNet: Eagle-Eye Multi-Scale Supervised Network for cardiac segmentation[J]. Biomedical Signal Processing and Control, 2024, 96: 106638.
- [54] ESTEVA A, KUPREL B, NOVOA R A, et al. Dermatologist-level classification of skin cancer with deep neural networks[J]. Nature, 2017, 542(7639): 115-118.
- [55] RAJPURKAR P, IRVIN J, ZHU K, et al. CheXNet: Radiologist-level pneumonia detection on chest X-rays with deep learning[J]. arXiv preprint arXiv:1711.05225, 2017.
- [56] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[C]//International Conference on Learning Representations. 2021.
- [57] LIU Z, WANG Y, VAIDYA S, et al. KAN: Kolmogorov-Arnold Networks[C]. 2024.
- [58] HE K, FAN H, WU Y, et al. Momentum contrast for unsupervised visual representation learning[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 9729-9738.
- [59] CHEN T, KORNBLITH S, NOROUZI M, et al. A simple framework for contrastive learning of visual representations[C]//International Conference on Machine Learning. 2020: 1597-1607.
- [60] HINTON G E, SRIVASTAVA N, KRIZHEVSKY A, et al. Improving neural networks by preventing co-adaptation of feature detectors[J]. arXiv preprint arXiv:1207.0580, 2012.
- [61] LIN T Y, GOYAL P, GIRSHICK R, et al. Focal loss for dense object detection[C]//Proceedings of the IEEE International Conference on Computer Vision. 2017: 2980-2988.
- [62] DOBADO A, PELAEZ J. Inverse amplitude method in chiral perturbation theory[J]. Physical Review D, 1997, 56(5): 3057.
- [63] LI H, LI H, QIU Z, et al. Domain adaptive retinal vessel segmentation guided by high-frequency component[C]//International Workshop on Ophthalmic Medical Image Analysis. 2022: 115-124.

- [64] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems: Vol. 30. 2017.
- [65] WANG X, GIRSHICK R, GUPTA A, et al. Non-local neural networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 7794-7803.
- [66] TING D S, CHEUNG C Y, LIM G, et al. Development and validation of a deep learning system for diabetic retinopathy and related eye diseases using retinal images from multiethnic populations with diabetes[J]. JAMA, 2017, 318(22): 2211-2223.
- [67] KINGMA D P, BA J. Adam: A method for stochastic optimization[C]//International Conference on Learning Representations. 2015.
- [68] LIU Q, YU L, CHEN P A, et al. Do we really need that many samples? A diagnostic study of sample diversity in medical image analysis[J]. Medical Image Analysis, 2022, 76: 102313.
- [69] LOSHCHILOV I, HUTTER F. Decoupled weight decay regularization[C]//International Conference on Learning Representations. 2019.
- [70] SELVARAJU R R, COGSWELL M, DAS A, et al. Grad-CAM: Visual explanations from deep networks via gradient-based localization[C]//Proceedings of the IEEE International Conference on Computer Vision. 2017: 618-626.
- [71] ZEILER M D, FERGUS R. Visualizing and understanding convolutional networks[C]//European Conference on Computer Vision. 2014: 818-833.
- [72] HOWARD A G, ZHU M, CHEN B, et al. MobileNets: Efficient convolutional neural networks for mobile vision applications[C]//arXiv preprint arXiv:1704.04861. 2017.
- [73] TAN M, LE Q. EfficientNet: Rethinking model scaling for convolutional neural networks[C]//International Conference on Machine Learning. 2019: 6105-6114.
- [74] KENDALL A, GAL Y. What uncertainties do we need in Bayesian deep learning for computer vision? [C]//Advances in Neural Information Processing Systems: Vol. 30. 2017.

致谢

首先，感谢导师刘江教授在毕业论文完成过程中给予的指导。从选题确定、实验方案设计到论文修改，刘老师都提供了耐心而具体的建议，使我能够逐步厘清研究思路并完善论文内容。刘老师严谨负责的治学态度也让我深受启发。感谢课题组老师和同学们在研究讨论、实验推进和论文写作中给予的帮助，尤其感谢实验室师兄师姐提供的经验分享和技术支持。与大家的交流让我对医学图像分析和科研训练有了更深入的理解。同时，感谢南方科技大学计算机科学与工程系提供的学习环境和科研条件，也感谢学校图书馆、计算平台等资源对本研究的支持。最后，感谢家人和朋友在本科阶段给予的理解与鼓励。毕业设计的完成离不开上述帮助，也让我在独立思考、问题分析和持续改进方面获得了重要成长。