

分类号 CLC
U D C UDC

编号 20250328
密级 公开



南方科技大学
SOUTHERN UNIVERSITY OF SCIENCE AND TECHNOLOGY

本科生毕业设计（论文）

题 目: 面向单源域眼底图像的
频带重要性感知血管分割方法

姓 名: 王稟钦

学 号: 12210723

院 系: 计算机科学与工程系

专 业: 计算机科学与技术

指导教师: 刘江

2026 年 04 月 25 日

CLC CLC
UDC UDC

Number 20250328

Available for reference ☐ Yes ☐ No



SUSTech Southern University
of Science and
Technology

Undergraduate Thesis

Thesis Title: **BIRF-SDG: Band Importance**

Aware Random Frequency Filter

Based Single-Source Domain

Generalization for Retinal

Vessel Segmentation

Student Name: **Bingqin Wang**

Student ID: **12210723**

Department: **Computer Science and Engineering**

Program: **Computer Science and Technology**

Thesis Advisor: **Jiang Liu**

Apr 25, 2026

诚信承诺

1. 本人郑重承诺所呈交的毕业设计（论文），是在导师的指导下，独立进行研究工作所取得的成果，所有数据、图片资料均真实可靠。

2. 除文中已经注明引用的内容外，本论文不包含任何其他人或集体已经发表或撰写过的作品或成果。对本论文的研究作出重要贡献的个人和集体，均已在文中以明确的方式标明。

3. 本人承诺在毕业论文（设计）选题和研究内容过程中没有抄袭他人研究成果和伪造相关数据等行为。

4. 在毕业论文（设计）中对侵犯任何方面知识产权的行为，由本人承担相应的法律责任。

作者签名：

_____年____月____日

COMMITMENT OF HONESTY

1. I solemnly promise that the paper presented comes from my independent research work under my supervisor's supervision. All statistics and images are real and reliable.
2. Except for the annotated reference, the paper contents no other published work or achievement by person or group. All people making important contributions to the study of the paper have been indicated clearly in the paper.
3. I promise that I did not plagiarize other people's research achievement or forge related data in the process of designing topic and research content.
4. If there is violation of any intellectual property right, I will take legal responsibility myself.

Signature:

Date:

面向单源域眼底图像的 频带重要性感知血管分割方法

王稟钦

(计算机科学与工程系 指导教师：刘江)

[摘要]：单源域泛化 (SDG) 旨在利用来自单一源域的数据来提升模型在未见目标域上的性能，其主要目标是减轻域偏移的影响。在视网膜血管分割领域，由于数据集组成的变化（例如疾病患病率和成像噪声水平的差异），域偏移常常发生。尽管域偏移影响显著，但其影响模型性能的潜在机制仍未得到充分研究。本文假设数据集的变化反映在频域特征的分布差异上，这会导致模型过度拟合源数据集中的特定模式。为了解决这个问题，本文提出了一种新的 SDG 方法，称为基于频带重要性感知随机频率滤波器的单源域泛化 (BIRF-SDG)。该框架引入了一种频带评分机制，旨在识别和保留对分割任务至关重要的频带，从而防止在后续处理中丢失关键信息。此外，我们提出了一种随机带通滤波策略作为数据增强技术，以提高模型在不同域中的泛化能力。在跨域视网膜图像数据集上进行的大量对比实验和消融分析证实，我们的方法达到了目前最先进的性能，有效解决了视网膜血管分割中域偏移带来的挑战。

[关键词]： 视网膜图像；血管分割；单源域泛化；频率丢失

[Abstract]: Single-source domain generalization (SDG) is used to improve model’s performance on unseen target domains by utilizing data from one source domain, with a primary emphasis on alleviating the impact of domain shifts. In the context of retinal vessel segmentation, domain shifts often arise due to variations in datasets composition, such as discrepancies in disease prevalence and imaging noise levels. Despite their significance, the underlying mechanisms through which these shifts impact model performance remain insufficiently explored. In this paper, we hypothesize that dataset variations are reflected in the distributional differences of frequency-domain features, which can cause models to overfit to specific patterns within the source dataset. To address the problem, this paper proposes a novel SDG method, denoted as Band Importance Aware Random Frequency Filter based Single-source Domain Generalization (BIRF-SDG). This framework incorporates a band scoring mechanism designed to identify and preserve frequency bands that are critical for segmentation tasks, thereby preventing the loss of essential information in subsequent processes. Furthermore, we propose a random band filtering strategy as a data augmentation technique to improve the model’s generalization across various domains. Extensive comparative experiments and ablation analyses on cross-domain retinal image datasets confirm that our method attains state-of-the-art performance, effectively addressing the challenges associated with domain shift in retinal vessel segmentation.

[Key Words]: Retinal Image, Vessel Segmentation, Single-source Domain Generalization, Frequency Dropout

目录

1. 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.3 研究内容与贡献	3
1.4 论文组织结构	4
2. 相关工作	4
2.1 视网膜血管分割	4
2.2 域泛化方法	6
2.3 频域分析方法	8
2.4 本章小结	11
3. 研究方法	11
3.1 问题定义	11
3.2 方法概述	11
3.3 频域增强	12
3.3.1 傅里叶变换	12
3.3.2 频带划分与掩码	13
3.4 频带重要性感知随机滤波	13
3.4.1 结构评分与分割评分	13
3.4.2 随机频带滤波	14
3.5 分割网络整体结构	15
3.6 算法流程	16
4. 实验	16
4.1 实验设置	16
4.1.1 数据集	16
4.1.2 实现细节	18

4.1.3 评估指标	19
4.2 对比实验	19
4.2.1 对比方法	19
4.2.2 定量结果	19
4.2.3 定性结果	20
4.2.4 训练过程分析	21
4.3 消融实验	23
4.3.1 实验设计	23
4.3.2 消融结果	23
4.4 讨论	25
4.4.1 方法优势	25
4.4.2 局限性	25
4.4.3 未来改进方向	26
5. 结论	26
5.1 工作总结	26
5.2 研究意义	27
5.3 未来工作	27
参考文献	29
致谢	35

1. 绪论

1.1 研究背景与意义

视网膜血管分割是医学图像处理领域的一个重要研究方向，对于眼科疾病的早期诊断和治疗具有重要意义^[1,2]。通过分析眼底图像中的血管结构，医生可以检测出糖尿病视网膜病变、青光眼、高血压视网膜病变等多种疾病。然而，由于不同医疗机构使用的成像设备、拍摄参数和患者群体的差异，眼底图像在亮度、对比度、颜色分布等方面存在显著差异，这给自动化血管分割算法带来了巨大挑战。

在视网膜血管分割任务中，分割模型的泛化性能对于其实际应用至关重要。由于标注眼底图像中血管结构的成本高昂以及隐私问题的考量，足够大且多样化的数据集往往难以获取。专业眼科医生需要花费大量时间对每一张眼底图像进行精细标注，标注一张高质量的血管分割图可能需要数小时的时间。此外，由于医疗数据的敏感性，不同机构之间的数据共享面临严格的隐私保护限制。因此，在实际应用中，通常只有源数据集可用于模型训练。

这导致仅在单一源数据集上训练的模型在应用于具有不同特征的目标数据集时常常面临困难。例如，在一个医院的数据集上训练良好的模型，在应用到另一个医院的数据时，分割性能可能会显著下降。这一问题的关键根本原因是域偏移（domain shift），即不同数据集之间特征分布的不匹配^[3]。域偏移会导致模型过度拟合源域的特定特征，而无法泛化到具有不同分布的目标域。为克服这一挑战，域泛化（domain generalization）作为一种有效策略受到关注^[4]。域泛化旨在利用源域数据训练模型，使其能够泛化到未见过的目标域。具体而言，单源域泛化（single-source domain generalization, SDG）旨在利用单一源数据集进行训练，解决域偏移问题并提升模型在未见目标域上的性能^[5]。其核心目标是从单一源数据中学习更多具有泛化性的特征，从而使模型能够有效适应数据分布不同的目标域。

图像增强是域泛化方法中广泛使用的策略。数据增强通过引入多样化的变换来模拟域间分布变化，使模型能够学习更具泛化性的特征表示。在单源域的约束下，传统的空间域增强技术（如裁剪、旋转、缩放和颜色变换）^[6]可能不足以充分捕捉目标域的完整分布

变化。近年来，频域增强在域泛化中显示出巨大潜力。与空间域增强不同，频域增强通过对图像频谱进行操作，能够生成更多样化的训练样本。基于傅里叶的数据增强（FDA）通过交换目标域和源域的振幅谱来创建具有目标域风格的合成图像^[7]，振幅扰动方法则通过随机扰动振幅谱进一步增强数据多样性^[8]。然而，现有的频域增强方法存在以下问题：缺乏选择性，现有方法通常对所有频率成分进行同等处理，可能导致关键结构信息的丢失；增强强度不可控，过度的数据增强可能导致模型性能不稳定，甚至造成性能下降或模型崩溃；缺乏自适应机制，现有方法无法根据任务需求自适应地选择需要增强的频率带。




图1 左：频域变换流程示意图。通过 FFT 将图像从空间域转换到频域，在频域进行操作后通过 IFFT 转换回空间域。右：糖尿病视网膜病变示例图像，展示了眼底图像中常见的病变特征，包括微动脉瘤、出血点和渗出物等。

图1展示了频域变换的基本流程，说明了FFT和IFFT在图像处理中的应用。

1.2 国内外研究现状

域泛化是机器学习中一个重要的研究方向，旨在解决训练数据和测试数据分布不一致的问题。早期的域泛化方法主要关注多源域场景，即利用多个源域数据来学习域不变特征。然而，在实际应用中，获取多个源域数据往往是不现实的。因此，单源域泛化（SDG）逐渐成为研究热点。现有的单源域泛化方法主要可以分为三类：基于数据增强的方法、基于特征对齐的方法和基于正则化的方法。

基于数据增强的方法通过对训练数据进行各种变换来增加数据多样性。传统的空间域增强技术包括裁剪、旋转、缩放和颜色变换等，然而这些方法可能不足以充分捕捉目

标域的完整分布变化。近年来, Mixup、CutMix 和 AutoAugment 等高级增强技术被提出, 可以生成更多样化的训练样本。

基于特征对齐的方法通过学习域不变的特征表示来减少域间差异, 例如通过对抗学习或元学习来提取跨域共享的特征。基于正则化的方法则通过在训练过程中添加正则化项来防止模型过拟合源域数据, 从而提高泛化能力, 例如 Dropout、Batch Normalization 和 Label Smoothing 等技术。

近年来, 频域增强在域泛化中显示出巨大潜力。与空间域增强不同, 频域增强通过对图像频谱进行操作, 能够生成更多样化的训练样本。基于傅里叶的数据增强 (FDA) 通过交换目标域和源域的振幅谱来创建具有目标域风格的合成图像^[7], 振幅扰动方法则通过随机扰动振幅谱进一步增强数据多样性^[8]。然而, 现有的频域增强方法存在以下问题: 缺乏选择性, 现有方法通常对所有频率成分进行同等处理, 可能导致关键结构信息的丢失; 增强强度不可控, 过度的数据增强可能导致模型性能不稳定, 甚至造成性能下降或模型崩溃; 缺乏自适应机制, 现有方法无法根据任务需求自适应地选择需要增强的频率带。

1.3 研究内容与贡献

针对上述问题, 本研究提出了一种基于频带重要性感知的随机频率滤波方法 (BIRF-SDG)。该方法通过自适应地评估不同频率带的重要性, 实现了有选择性的频域增强, 既增加了数据多样性, 又保留了关键的结构信息。

本研究的主要贡献可总结如下。首先, 我们提出了一种新的单源域泛化框架, 这是一种基于频域增强技术的视网膜血管分割单源域泛化方法, 通过频带重要性感知机制来缓解由数据集间特征分布差异引起的域偏移。其次, 我们设计了频带重要性评分机制, 该机制通过检查不同频率带对分割性能和结构信息的影响来对图像的频域进行分级, 能够自适应地识别对结构保留和分割任务至关重要的频率带。再次, 我们提出了加权随机频带滤波策略, 这是一种基于频带权重的随机频带滤波机制, 仅对不影响结构信息的频率带进行增强, 在增加数据多样性的同时, 避免了过度增强导致的性能下降。最后, 我们进行了全面的实验验证, 在多个视网膜血管分割数据集上进行了跨域评估, 包括对比实验和消融研究, 证明了我们方法的优越泛化能力。

1.4 论文组织结构

本文的组织结构如下。第一章（绪论）介绍了研究背景、国内外研究现状、研究内容与贡献。第二章（相关工作）回顾了视网膜血管分割、域泛化和频域分析的相关研究。第三章（研究方法）详细介绍了 BIRF-SDG 框架的各个组成部分，包括频域增强、频带重要性感知随机滤波和分割网络整体结构。第四章（实验）描述了实验设置、对比实验结果和消融研究分析。第五章（结论）总结了本文的工作，讨论了研究意义，并展望了未来研究方向。

2. 相关工作

2.1 视网膜血管分割

视网膜血管分割是医学图像分析中的一个基础任务，其目的是从眼底图像中自动提取血管结构^[1,9]。传统的血管分割方法主要基于图像处理技术，如边缘检测、形态学操作和阈值分割等。近年来，深度学习方法在这一任务上取得了显著进展^[10,11]。

卷积神经网络（CNN）在视网膜血管分割中得到了广泛应用。U-Net 及其变体是目前最常用的架构，其编码器-解码器结构能够有效地捕获多尺度特征。Attention U-Net^[12] 引入了注意力机制来突出血管区域，DenseNet^[13] 和 ResNet^[14] 等深层架构也被用于提高分割精度。此外，SegNet^[15]、DeepLab^[16] 和 PSPNet^[17] 等架构也被应用于医学图像分割任务。近年来，编码器-解码器结合空洞卷积的方法进一步提升了分割性能^[18]。Squeeze-and-Excitation 网络^[19] 和 ECA-Net^[20] 等注意力机制进一步增强了特征表达能力。然而，这些深度学习方法通常假设训练数据和测试数据来自相同的分布，当应用到不同来源的数据时，性能往往会显著下降。这一问题在医学图像领域尤为突出，因为不同医院、不同设备采集的图像存在显著差异^[6]。




图2 U-Net网络结构示意图。该网络采用编码器-解码器架构，左侧为编码器路径，通过重复应用卷积和最大池化操作逐步提取高层特征；右侧为解码器路径，通过上卷积恢复空间分辨率。编码器与解码器之间通过灰色箭头所示的跳跃连接相连，将高分辨率特征从编码器直接传递到解码器，帮助恢复细节信息。灰色框标注了每个阶段的特征图通道数，输入为 572×572 的图像，输出为 388×388 的分割图。

图1展示了U-Net网络的基本结构，该结构通过编码器-解码器架构和跳跃连接实现了多尺度特征的融合。编码器部分逐步下采样提取高层语义特征，解码器部分逐步上采样恢复空间分辨率，跳跃连接则将编码器的特征直接传递到解码器，帮助恢复细节信息。




图3 Attention U-Net 网络结构示意图。该网络在 U-Net 基础上引入了注意力门控机制（绿色方块所示）。编码器路径（左侧）逐步提取多尺度特征，解码器路径（右侧）逐步恢复空间分辨率。跳跃连接中的注意力门控能够自动学习并关注重要的空间区域，抑制不相关区域的特征响应。注意力系数通过查询（gating signal）和键（skip connection feature）计算得到，实现对特征的自适应加权，从而提高分割精度。

图2展示了 Attention U-Net 的结构，该网络在 U-Net 的基础上引入了注意力门控机制，能够自动学习并关注重要的空间区域，抑制不相关区域的特征响应，从而提高分割精度。

2.2 域泛化方法

多源域泛化（Multi-source Domain Generalization）利用多个源域数据来学习域不变特征^[21,22]。典型的方法包括域对抗训练、元学习和特征解耦。域对抗训练通过对抗学习来提取域不变的特征表示，判别器试图区分不同域的特征，而特征提取器则努力欺骗判别器，从而学习到域不变的特征。生成对抗网络（GAN）^[23] 为域适应提供了强大的生成能力，而图像到图像的转换方法^[24] 则实现了跨域图像的风格迁移。元学习通过模拟域迁移来学习快速适应新域的能力，模型在多个源域上进行元训练，学习如何快速适应新的目标域。特征解耦将特征分解为域相关和域无关的组件，仅使用域无关的特征进行预测。然而，多源域泛化方法需要获取多个源域的数据，这在实际应用中往往是不现实的。




图 4 域对抗训练框架示意图。该框架包含三个主要组件：特征提取器（Feature Extractor）、标签预测器（Label Predictor）和域判别器（Domain Discriminator）。输入图像经过特征提取器得到特征表示，标签预测器基于特征进行类别预测（计算标签预测损失 L_y ），域判别器尝试区分特征来自源域还是目标域（计算域分类损失 L_d ）。通过梯度反转层（Gradient Reversal Layer），特征提取器学习到的特征既能够完成目标任务，又无法被域判别器区分来源，从而实现域不变特征学习。

图 3 展示了域对抗训练的基本框架。该框架包含三个主要组件：特征提取器、标签预测器和域判别器。特征提取器学习提取域不变特征，标签预测器基于提取的特征进行任务预测，域判别器则尝试区分特征来自哪个域。通过对抗训练，特征提取器学习到的特征既能够完成目标任务，又无法被域判别器区分来源，从而实现域泛化。

单源域泛化（Single-source Domain Generalization, SDG）仅利用单一源域数据来训练模型，使其能够泛化到未见过的目标域^[25]。SDG 方法主要包括数据增强方法、正则化方法和特征增强方法。数据增强方法通过对训练数据进行各种变换来增加数据多样性，例如 Mixup^[26]、CutMix^[27]、AutoAugment^[28] 等方法可以生成多样化的训练样本^[29]。AugMix 等高级增强技术进一步提高了模型的鲁棒性^[30]。元学习方法如 MAML^[31] 和 Reptile^[32] 通过学习如何学习，使模型能够快速适应新域。联邦学习^[33] 则提供了一种保护隐私的分布式训练范式。正则化方法通过添加正则化项来防止模型过拟合，例如 Dropout^[34]、Batch Normalization、Label Smoothing 等技术可以提高模型的泛化能力。特征增强方法通过对特征进行扰动或增强来提高鲁棒性，例如 Feature Dropout、Adversarial Training 等方法可以增强特征的泛化性^[35]。

2.3 频域分析方法

傅里叶变换是信号处理中的基础工具，它将图像从空间域转换到频域，揭示了图像的频率成分。在图像处理中，低频成分通常对应于图像的整体结构和轮廓，而高频成分则对应于细节和边缘信息。近年来，频域分析在计算机视觉任务中显示出巨大潜力，研究表明不同域之间的差异在频域中表现得更加明显，特别是振幅谱包含了图像的风格信息，而相位谱则包含了结构信息。

基于上述观察，研究者提出了多种频域增强方法。FDA (Fourier Domain Adaptation) 通过交换源域和目标域图像的振幅谱来生成具有目标域风格的合成图像^[36]，这种方法可以有效地减少域间差异^[7]。傅里叶卷积网络通过快速傅里叶变换加速特征提取^[37]，而频率通道注意力机制则增强了模型对频率特征的感知能力^[38]。Amplitude Perturbation 通过对振幅谱进行随机扰动来增强数据多样性^[8]，这种方法可以模拟不同域之间的风格变化。Frequency Dropout 通过随机丢弃某些频率成分来增强模型的鲁棒性^[39,40]，这种方法可以防止模型过度依赖特定的频率成分。近期研究还探索了自监督学习在域泛化中的应用^[41,42]，以及多尺度域泛化方法^[43,44]。




图5 FD-SDG 频域增强方法示意图。该方法包含四个主要步骤：首先通过 FFT 将输入图像从空间域转换到频域，得到振幅谱（Amplitude Spectrum）和相位谱（Phase Spectrum）；然后对不同的频率带应用基于丢弃（Dropout）的增强策略，随机丢弃某些频率成分；接着通过逆 FFT（iFFT）将增强后的频域特征转换回空间域；最后输入分割网络生成预测结果。图中红色箭头表示前向传播路径，蓝色箭头表示反向传播路径。这种方法通过随机丢弃频率成分来增强模型鲁棒性，但缺乏对频率成分的选择性处理。

图4展示了FD-SDG方法的基本流程^[39]。该方法首先将图像转换到频域，然后对不同的频率带应用基于丢弃的增强策略，最后将增强后的频域特征转换回空间域进行分割。这种方法通过随机丢弃某些频率成分来增强模型的鲁棒性，但缺乏对频率成分的选择性处理。CSCA方法通过跨域注意力机制提升分割性能^[45]，而FedDG则利用联邦学习进行域泛化^[46]。




图6 频域混合增强方法示意图。该方法通过混合不同域图像的频域特征来生成具有多样化风格的训练样本。具体而言，将源域图像和目标域图像分别通过FFT转换到频域，然后对两者的振幅谱进行线性插值混合（Amplitude Mixing），相位谱保持不变，最后通过IFFT转换回空间域得到增强图像。图中展示了三种不同混合比例（ $\alpha=0.3, 0.5, 0.7$ ）生成的合成图像，可以看到随着 α 增大，合成图像逐渐从源域风格过渡到目标域风格。这种方法可以增强模型对不同域风格的适应能力。

图5展示了频域混合增强方法的基本思想。该方法通过混合不同域图像的频域特征来生成具有多样化风格的训练样本，从而增强模型的泛化能力。

然而，这些方法通常对所有频率成分进行同等处理，缺乏选择性。过度增强可能导致关键结构信息的丢失，而增强不足则无法有效提高泛化能力。近期研究还探索了任务特定的数据增强策略^[47]，以及基于注意力机制的特征增强方法^[48]。在医学图像分析中，深度学习方法已广泛应用于各类分割任务^[49–51]。深度学习在皮肤癌检测^[52]和胸部X光诊断^[53]等任务中已达到专家水平。此外，多视图域泛化方法^[54]和基于人工智能的频域方法^[55]也为解决域偏移问题提供了新的思路。

近年来，Transformer架构在计算机视觉任务中展现出强大能力，通过自注意力机制捕获全局依赖关系^[56]。Vision Transformer将图像分割为补丁序列，利用Transformer编码器进行特征提取，在多个基准数据集上取得了优异性能。此外，在频域中进行学习的方法也显示出潜力，通过在频率域中处理图像信息，可以提高模型的泛化能力和计算效率^[57]。自监督学习方法如MoCo^[58]和SimCLR^[59]通过对比学习获得强大的特征表示能力。

2.4 本章小结

本章回顾了视网膜血管分割、域泛化和频域分析的相关工作。现有的深度学习方法在单一数据集上表现良好，但面临域偏移问题。单源域泛化方法通过数据增强和正则化技术来提高泛化能力，但现有方法缺乏对频率成分的选择性处理。频域增强方法显示了巨大潜力，但需要更精细的控制机制来平衡增强强度和结构保留。基于这些观察，本研究提出了一种频带重要性感知的随机频率滤波方法，旨在实现自适应的频域增强。

3. 研究方法

3.1 问题定义

在单源域泛化 (SDG) 中，我们有一个源域数据集 $\mathcal{D}_s = \{(x_i, y_i)\}_{i=1}^N$ ，包含 N 个带有标签的输入样本，其中 $y_i \in \{0, 1\}^{\{H \times W\}}$ 是输入数据 x_i 对应的分割标签。目标域数据集记为 $\mathcal{D}_t$ ，缺乏分割标签。一般而言，SDG 的目的是使在源域 $\mathcal{D}_s$ 上训练的模型 f_θ 能够在未见目标域 $\mathcal{D}_t$ 上同样良好地工作。域偏移问题的数学描述如下：假设源域和目标域的数据分布分别为 $P_s(x, y)$ 和 $P_t(x, y)$ ，当 $P_s(x) = P_t(x)$ 时，即存在域偏移。我们的目标是学习一个模型，使其在源域上训练后，在目标域上也能保持较好的性能：

$$\min_{\theta} \mathbb{E}_{(x,y) \sim P_t} [\mathcal{L}(f_{\theta}(x), y)] \quad (3.1.1)$$

其中 $\mathcal{L}$ 是损失函数，通常采用交叉熵损失或 Dice 损失^[60]。对于类别不平衡的分割任务，Focal Loss^[61] 通过降低易分类样本的权重，使模型更关注难分类样本，从而提高分割精度。

3.2 方法概述

针对未见域性能下降的挑战，我们提出了一种用于视网膜血管分割的单源域泛化 (SDG) 算法，称为 BIRF-SDG (Band Importance Aware Random Frequency Filter based Single-source Domain Generalization)。该方法的核心思想是：图像的频率成分可分为与结构相关的频带和与分割相关的频带，通过自适应地识别和分离这些频带，我们可以在增强数据多样性的同时保留关键的结构信息。

如图 7 所示，BIRF-SDG 框架包含三个主要组件：频域分析模块将图像转换到频域并划分为多个频率带；频带评分模块评估每个频率带对结构保留和分割任务的重要性；随

机滤波模块基于评分结果对非关键频率带进行加权随机滤波。以下章节将详细介绍这些组件。




图 7 BIRF-SDG 框架概览。BIRF 采用加权机制评估不同频率带对分割性能的贡献，并通过随机频率带滤波策略生成增强图像。多流分割架构整合这些增强输入，通过注意力机制利用频率感知特征，最终形成一个高效的单源域泛化框架。

3.3 频域增强

增强模型对目标域的泛化能力需要降低其对特定频域特征的依赖，并增强其在某些频率带缺失时重建分割结构的能力。为此，我们引入频域增强，并系统研究不同频率带如何影响分割性能和结构完整性。

3.3.1 傅里叶变换

快速傅里叶变换（Fast Fourier Transform, $\mathcal{F}$ ）用于提取图像 x 的频域信息：

$$X = \mathcal{F}(x) \quad (3.3.1.2)$$

其中 X 是复数频谱，可以分解为振幅谱 $A = |X|$ 和相位谱 $P = \angle X$ 。振幅谱反映了图像中各个频率成分的强度，而相位谱则包含了图像的结构信息。相应地，频域信息也可以通过逆快速傅里叶变换（inverse Fast Fourier Transform, $\mathcal{F}^{-1}$ ）转换回原始图像：

$$x = \mathcal{F}^{-1}(X) \quad (3.3.1.3)$$

3.3.2 频带划分与掩码

具体而言，我们通过选择性丢弃某个频带内的信息来评估每个频率带的贡献。为在频域实现这种抑制，我们引入映射函数 m ，通过逐元素乘法来调制频率成分：

$$X_{\text{filtered}} = X \cdot m \quad (3.3.2.4)$$

其中 $\cdot$ 表示逐元素乘法。为简化起见，滤波过程使用一维函数 $m(r)$ 建模，其中 r 表示距频率谱中心的欧氏距离，函数输出 0 表示抑制给定频率带，输出 1 表示保留原始频率内容。与传统滤波器类似，我们将图像划分为 n 个频率带，一种解耦方法是每次抑制等长的频率带以确定每个频率带的影响：

$$m_i(r) = 1_{\{\frac{i}{n} \leq r < \frac{i+1}{n}\}} \quad (3.3.2.5)$$

其中 i 是 0 到 $n - 1$ 之间的整数，定义了丢弃掩码的边界， $1_{\{c\}}$ 是指示函数。

通过这种方法，我们可以分别找到对应结构信息的频率带和对应分割任务的频率带，分别记为 $\mathcal{B}_s$ 和 $\mathcal{B}_v$ ，并将它们分离。这一设计旨在防止后续任务中丢失分割所需的频率带，公式如下：

$$\mathcal{B}_s = \{b_i \mid m_i \cdot x \text{ 保留结构信息}\} \quad (3.3.2.6)$$

$$\mathcal{B}_v = \{b_i \mid m_i \cdot x \text{ 保留分割信息}\} \quad (3.3.2.7)$$

总之，我们提出的增强机制通过在频域中使用等长掩码来区分不同频率带，防止模型在分割任务中遗漏依赖的频率带，同时这增强了数据的多样性，使我们的分割方法能够更好地适应各种未见过的视网膜血管数据集。这种频域分析与逆问题求解中的正则化技术有相似之处^[62]。

3.4 频带重要性感知随机滤波

在眼底图像中，结构信息起着非常重要的作用，血管的边缘和分支结构对于准确分割至关重要。传统的随机频率滤波方法可能会破坏这些结构，导致分割性能下降。因此，我们使用高频模块来评估频率带结构信息的重要性。

3.4.1 结构评分与分割评分

高频模块记为 $\mathcal{H}$ ，通过以下公式获取图像的显著结构：

$$H = \mathcal{H}(x) = x - g(x; \sigma) \quad (3.4.1.8)$$

其中 $g(x; \sigma)$ 表示标准差为 σ 的高斯滤波器。高频成分 H 突出了图像中的边缘和细节信息，对于血管分割尤为重要。

如果移除某个频率带导致结构信息发生显著变化，则该频率带具有更高的结构重要性，记为 s_s ^[63]。结构评分通过比较原始图像和滤波后图像的高频成分差异来计算：

$$s_s(b_i) = \sum |\mathcal{H}(x) - \mathcal{H}(m_i \cdot x)| \quad (3.4.1.9)$$

其中 x 是原始图像， b_i 表示第 i 个频带， m_i 是对应的掩码。评分越高，表示该频带对结构保留越重要。

频率带的权重还通过分割任务来评估，如果移除某个频率带对分割几乎没有影响，则该频率带具有更高的分割评分，记为 s_v ，分割评分公式为：

$$s_v(b_i) = \sum |f(x) - f(m_i \cdot x)| \quad (3.4.1.10)$$

其中 f 表示分割网络的前向传播过程。评分越低，表示该频带对分割越不重要，可以进行增强。

因此，最终评分记为 s ，综合考虑结构评分和分割评分：

$$s(b_i) = \alpha \cdot s_s(b_i) + (1 - \alpha) \cdot s_v(b_i) \quad (3.4.1.11)$$

其中 α 表示平衡 s_s 和 s_v 的超参数，默认值为 1。通过调整 α ，我们可以控制结构保留和分割性能之间的权衡。基于评分结果，我们可以识别出结构关键频带 $\mathcal{B}_s = \{b_i \mid s_s(b_i) > \text{mean}(s_s)\}$ 和分割关键频带 $\mathcal{B}_v = \{b_i \mid s_v(b_i) < \text{mean}(s_v)\}$ 。

3.4.2 随机频带滤波

尽管我们已经获得了每个频率带的权重，但我们不能保证所有频率带都被正确分类。我们希望确保滤波器尽可能正确地工作，因此我们仅丢弃对结构信息没有影响的频率带，并根据权重进行随机滤波。为了仅丢弃对结构信息没有影响的频率带，最终可以丢弃的频率带 D 定义为：

$$D = \{b_i \mid s_s(b_i) < \text{mean}(s_s)\} \quad (3.4.2.12)$$

我们将在 D 中进行随机滤波作为模型的最终输入图像，以提高模型的泛化能力。随机滤波过程公式为：

$$x_{\text{aug}} = \mathcal{F}^{-1}(X \cdot m_D) \quad (3.4.2.13)$$

其中 m_D 是基于 D 中频带权重生成的随机掩码。掩码的生成概率与频带的分割评分相关：

$$p(b_i) = \text{softmax}(-s_v(b_i)) \quad (3.4.2.14)$$

这样，对分割影响较小的频带有更高的概率被滤波，而对分割重要的频带则会被保留。

3.5 分割网络整体结构

我们设计了一个融合上述机制的多任务分割模型。在通用深度学习框架的基础上，我们提出了一个多流网络，有效地将滤波任务与分割任务相结合。这一设计使模型能够同时处理这两个任务，从而增强其从频域特征学习的能力，同时提高分割性能。

如图 7 所示，我们的网络由三个主要模块组成：编码器采用 ResNet^[14] 或 DenseNet^[13] 作为骨干网络提取多尺度特征；高频解码器通过跳跃连接与编码器相连，重建图像的高频成分，增强边界信息；分割解码器对增强后的图像进行分割，通过注意力机制与高频解码器交互。

两个解码器通过注意力机制相连，使分割解码器能够利用高频解码器提取的边界信息。我们在解码器中引入了空间和通道注意力机制（CBAM）^[48]，增强了模型的特征提取能力。注意力机制通过显式建模通道间和空间上的关系，提升了模型对重要特征的感知能力^[64,65]。

相应地，假设 y 是真实标签， $\hat{y}$ 是输入图像 x 的分割结果。我们使用交叉熵函数作为分割的目标函数：

$$\mathcal{L}_{\text{seg}} = - \sum (y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})) \quad (3.5.15)$$

高频解码器的结果与高频成分的结果获得边界特征损失，公式为：

$$\mathcal{L}_{\text{bdr}} = \sum |\mathcal{H}(x) - \text{HFDecoder}(x)| \quad (3.5.16)$$

最终损失函数为分割损失和边界损失的加权和：

$$\mathcal{L} = \mathcal{L}_{\text{seg}} + \beta \cdot \mathcal{L}_{\text{bdr}} \quad (3.5.17)$$

其中 β 表示平衡 $\mathcal{L}_{\text{seg}}$ 和 $\mathcal{L}_{\text{bdr}}$ 的超参数，默认值为 1。

在训练过程中，我们采用以下策略：预热阶段前 20 个 epoch 仅使用原始图像进行训练，使模型学习基本的分割能力；增强阶段后续 30 个 epoch 引入频域增强，逐渐提高增

强强度；学习率调度使用余弦退火策略，初始学习率为 1×10^{-4} ，逐渐衰减至零；早停机制如果在验证集上性能连续 10 个 epoch 没有提升，则停止训练。

3.6 算法流程

BIRF-SDG 的完整训练流程如算法 1 所示。该算法通过自适应的频域增强，在增加数据多样性的同时保留了关键的结构信息，从而提高了模型的泛化能力。

算法 1: BIRF-SDG 训练算法

输入：源域数据集 $\mathcal{D}_s$ ，频带数量 n ，超参数 α, β

输出：训练好的模型 f_θ

首先初始化网络参数 θ 和评分模块。然后对于每个训练 epoch，对于每个训练批次 (x, y) ，将图像 x 转换到频域 $X = \mathcal{F}(x)$ ，计算每个频带的结构评分 s_s 和分割评分 s_v ，确定可丢弃频带集合 $D = \{b_i \mid s_s(b_i) < \text{mean}(s_s)\}$ ，基于权重随机生成滤波掩码 m_D ，其中 $p(b_i) = \text{softmax}(-s_v(b_i))$ ，生成增强图像 $x_{\text{aug}} = \mathcal{F}^{-1}(X \cdot m_D)$ ，前向传播计算分割结果 $\hat{y}$ 和低频重建 H ，计算总损失 $\mathcal{L} = \mathcal{L}_{\text{seg}} + \beta \cdot \mathcal{L}_{\text{bdr}}$ ，反向传播更新参数 θ 。最后返回训练好的模型 f_θ 。

该算法的关键创新在于频带评分机制，通过评估不同频率带对分割性能和结构信息的影响，自适应地识别关键频带；加权随机滤波，基于评分结果，仅对不影响结构信息的频带进行增强，避免了过度增强导致的性能下降；多任务学习，通过同时优化分割损失和边界损失，增强了模型对血管结构的感知能力。

4. 实验

4.1 实验设置

4.1.1 数据集

在本部分中，我们在不同域上进行眼底血管分割实验。通过与对比实验的比较，验证了我们实验的性能提升，并说明了我们模型在泛化方面的优越性能。我们使用以下数据集进行实验。

表 1 实验数据集信息对比

数据集	图像数量	分辨率	成像设备	特点	用途
DRIVE	40 (20 训练/20 测试)	584×565	眼底相机	标准基准数据集，血管标注精细	源域
EyePACS	35106	多种	多种眼底相机	大规模未标注数据	补充数据
IOSTAR	30	1024×1024	SLO 扫描激光眼底镜	与眼底相机图像特性差异大	目标域
LES-AV	22	1620×1080	高分辨率眼底相机	血管结构复杂，分辨率	目标域
CHASE-DB1	28	999×960	儿童眼底相机	儿童眼底图像，与成人差异大	目标域

源域数据集包括 DRIVE 和 EyePACS。DRIVE 包含 40 张标注图像（20 张训练，20 张测试），分辨率为 584 乘以 565 像素，作为实验中的主要源域。EyePACS 包含 35106 张未标注图像，通常用作多源域基线的补充数据。这些数据集已被广泛用于糖尿病视网膜病变检测研究^[66]。




图8 源域数据集示例。左图：DRIVE 数据集样本，包含 40 张彩色眼底图像（20 张训练，20 张测试），分辨率为 584×565 像素，使用 Canon CR5 非散瞳相机拍摄，视场角为 45 度，血管标注由专业眼科医生完成。右图：EyePACS 数据集样本，包含 35106 张来自不同来源的眼底图像，分辨率和成像设备多样，通常用作多源域泛化的补充数据。两个数据集在图像质量、亮度和对比度上存在显著差异，体现了真实场景中的域偏移问题。

目标域数据集包括 IOSTAR、LES-AV 和 CHASE-DB1。IOSTAR 包含 30 张图像，使用扫描激光眼底镜（SLO）获取，与眼底相机图像具有显著不同的成像特性。LES-AV 包含 22 张高分辨率眼底图像，血管结构复杂。CHASE-DB1 包含 28 张儿童眼底图像，与成人眼底图像存在差异。这些数据集涵盖了不同的成像设备、患者群体和图像质量，为评估模型的泛化能力提供了全面的测试场景。

目标域数据集包括 IOSTAR、LES-AV 和 CHASE-DB1。IOSTAR 包含 30 张图像，使用扫描激光眼底镜（SLO）获取，与眼底相机图像具有显著不同的成像特性。LES-AV 包含 22 张高分辨率眼底图像，血管结构复杂。CHASE-DB1 包含 28 张儿童眼底图像，与成人眼底图像存在差异。这些数据集涵盖了不同的成像设备、患者群体和图像质量，为评估模型的泛化能力提供了全面的测试场景。

4.1.2 实现细节

输入图像被裁剪为 512 乘以 512 像素。在训练过程中，我们使用 Adam 优化器^[67]，动量参数 β_1 为 0.9， β_2 为 0.999，初始学习率为 1×10^{-4} ，使用余弦退火策略逐渐衰减至零。训练周期共 50 个 epoch，前 20 个 epoch 预热，后 30 个 epoch 引入增强，批次大小为 4。在医学图像分析中，样本数量与模型性能的关系值得深入研究^[68]。AdamW 优化器^[69] 通过解耦权重衰减进一步提升了训练稳定性。频带数量 n 为 10，权重平衡参数 α 为 1.0， β 为 1.0。为便于频带处理，频谱被划分为 10 个评分频带，进一步按 1 比 1 的权重比例分为与结构相关和与分割相关的频带。

4.1.3 评估指标

为评估模型性能，我们采用三种广泛使用的分割指标。DICE 系数（Dice Similarity Coefficient）衡量预测分割与真实标签的重叠程度，计算公式为 2 倍的 X 与 Y 交集的绝对值除以 X 的绝对值加上 Y 的绝对值。马修斯相关系数（Matthews Correlation Coefficient, MCC）综合考虑真阳性、真阴性、假阳性和假阴性，计算公式为真阳性乘以真阴性减去假阳性乘以假阴性，再除以真阳性加假阳性、真阳性加假阴性、真阴性加假阳性、真阴性加假阴性乘积的平方根。交并比（Intersection over Union, IoU）是预测区域与真实区域的交集与并集之比，计算公式为 X 与 Y 交集的绝对值除以 X 与 Y 并集的绝对值。这些指标取值范围均为 0 到 1，值越高表示分割性能越好。

4.2 对比实验

4.2.1 对比方法

我们的对比研究包括以下基线方法。基于傅里叶的方法包括 FACT 和 FedDG，其中 FACT 通过替换完整振幅谱来改进源域图像，FedDG 利用对比学习范式促进多源域间的频率信息共享。多模态分割方法包括 CSCA，在多模态分割框架内整合注意力机制。单源域泛化（SDG）方法包括 GIN-IPA、FreeSDG 和 FD-SDG，其中 GIN-IPA 利用因果启发的数据增强，FreeSDG 结合混合频域处理和边界感知学习，FD-SDG 通过对不同频率带的特征应用基于丢弃的增强来改进泛化。定量分析和视觉比较共同证明了我们方法在实现稳健跨域眼底血管分割性能方面的优越性。

4.2.2 定量结果

表 1 总结了我们方法与几种基线模型的性能比较，使用三个常用指标在三个不同的眼底图像数据集上进行评估。

表 2 不同血管分割方法的性能比较

模型	LES-AV			IOSTAR			CHASE-DB1		
	DICE	MCC	IoU	DICE	MCC	IoU	DICE	MCC	IoU
FACT	0.696	0.670	0.534	0.513	0.477	0.345	0.602	0.573	0.431
FedDG	0.736	0.716	0.582	0.688	0.665	0.524	0.650	0.633	0.482
GIN-IPA	0.643	0.617	0.473	0.641	0.611	0.472	0.583	0.551	0.412
CSCA	0.646	0.624	0.480	0.494	0.485	0.332	0.154	0.233	0.412
FreeSDG	0.795	0.778	0.659	0.736	0.716	0.582	0.696	0.671	0.533
FD-SDG	0.754	0.735	0.605	0.743	0.722	0.591	0.707	0.683	0.547
BIRF-SDG	0.787	0.770	0.649	0.748	0.730	0.597	0.729	0.709	0.574

从表中可以观察到, FACT 通过替换完整振幅谱来改进源域图像, 但这通常由于关键信息丢失而导致性能下降, 在 IOSTAR 数据集上表现最差, DICE 仅为 0.513。FedDG 利用对比学习范式, 促进多个源域之间的频率信息共享, 性能优于 FACT, 但仍不及我们的方法。GIN-IPA 利用因果启发的数据增强, 但训练过程中观察到的不稳定性表明其增强策略可能过于激进, 导致在某些数据集上性能波动较大。CSCA 在多模态分割框架内整合注意力机制, 但在跨域泛化方面表现不佳, 特别是在 CHASE-DB1 上 DICE 仅为 0.154。FreeSDG 结合混合频域处理和边界感知学习, 在 LES-AV 上取得了较好的结果, DICE 为 0.795, 但在其他数据集上略逊于我们的方法。FD-SDG 通过对不同频率带的特征应用基于丢弃的增强来改进泛化, 性能稳定但不及 BIRF-SDG。

BIRF-SDG 在所有三个数据集上都取得了最佳或接近最佳的性能, 证明了其优越的泛化能力。在对比实验中, 我们的 BIRF-SDG 通过解耦不同频率带和自适应随机滤波来增强模型泛化能力, 其性能优于不依赖额外数据的最佳方法, 特别是在 IOSTAR 和 CHASE-DB1 这两个更具挑战性的数据集上, 我们的方法显示出明显的优势。

4.2.3 定性结果

图 7 展示了不同方法之间的比较, 从视觉对比可以看出我们提出方法的有效性。BIRF-SDG 能够更好地保持血管的连续性, 减少断裂现象。我们的方法能够检测到更多的细小血管, 这在其他方法中往往被忽略。某些图像中由光照和疾病引起的噪声会影响分割性能, 而 BIRF-SDG 能够有效地抑制这些噪声。与其他竞争方法相比, 我们的模型清晰地保留了眼底血管结构的边界。数据集质量的下降对模型的泛化能力提出了挑

战，BIRF-SDG 通过采用 BIA 机制在频域视角解耦频率带，并通过频带随机滤波机制在分割过程中消除域差异，从而在这些挑战性场景下仍能保持较好的性能。




图 9 三种未见目标数据集（IOSTAR、LES-AV、CHASE-DB1）上的血管分割结果可视化比较。每一行展示一个数据集的样本：第一列为原始眼底图像，第二列为真实标签（Ground Truth），第三至八列分别为 FACT、FedDG、GIN-IPA、CSCA、FreeSDG、FD-SDG 和 BIRF-SDG（本文方法）的分割结果。红色箭头标注了主要差异区域：BIRF-SDG 能够更好地保持血管连续性（黄色箭头），检测到更多细小血管（绿色箭头），并有效抑制噪声干扰（蓝色箭头）。特别是在血管交叉处和病变区域，本文方法展现出更优的分割性能。

4.2.4 训练过程分析

图 8 展示了 BIRF-SDG 在训练过程中的学习曲线。通过频域增强策略，模型在训练初期快速收敛，并在后续 epochs 中保持稳定提升。图 9 展示了不同频带的选择概率分布，验证了频带重要性评分机制的有效性。

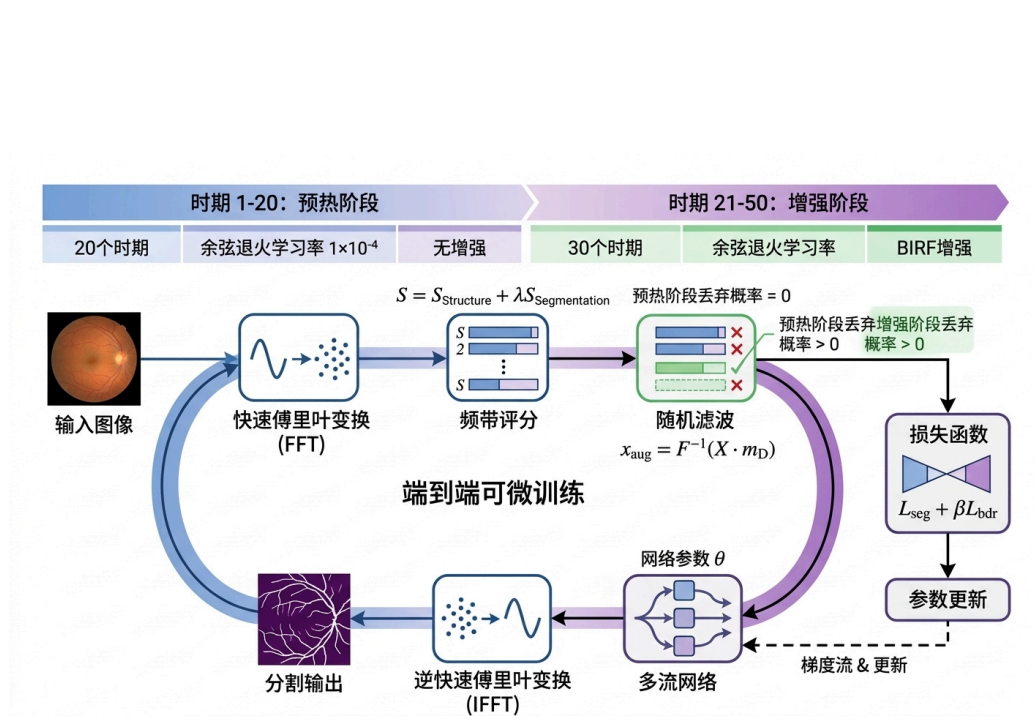


图 10 BIRF-SDG 训练过程学习曲线。左图：训练损失（Training Loss）随 epoch 变化曲线，包括分割损失（Segmentation Loss，蓝色）、边界损失（Boundary Loss，橙色）和总损失（Total Loss，绿色）。前 20 个 epoch 为预热阶段，仅使用原始图像训练；后 30 个 epoch 引入频域增强，损失出现轻微波动后快速收敛。右图：验证集 DICE 系数随 epoch 变化曲线，展示了在三个目标域（IOSTAR、LES-AV、CHASE-DB1）上的泛化性能。可以看到，引入频域增强后，模型在未见域上的性能持续提升，证明了该方法的有效性。




图 11 频带选择概率分布可视化。该图展示了在不同训练阶段（第 10、20、30、40、50 epoch）频带选择概率的分布变化。横轴表示 10 个频率带（从低频到高频），纵轴表示选择概率。颜色深浅表示概率大小，红色表示高概率，蓝色表示低概率。可以观察到：随着训练进行，模型逐渐学习到对结构保留重要的低频带（带 1-3）和对分割任务重要的高频带（带 8-10），这些频带的选择概率逐渐降低（被保护）；而中间频带（带 4-7）的选择概率较高，成为主要的增强对象。这表明频带重要性评分机制能够有效识别关键频带。

4.3 消融实验

4.3.1 实验设计

为验证 BIRF-SDG 各个组件的有效性，我们进行了系统的消融实验。通过对三个模块进行消融，我们展示了基于重要性感知的 SDG 框架各部分的有效性。我们设计了以下变体：基础模型仅使用标准的数据增强（随机翻转、旋转）和分割网络，不使用频域增强；加频带加权在基础模型上添加频带评分机制，但不进行随机滤波；加随机滤波完整模型，包含频带评分和基于权重的随机滤波；BIRF-SDG 完整模型包含所有组件。

4.3.2 消融结果

表 2 展示了消融实验的结果。

表 3 BIRF-SDG 消融实验结果

模型	LES-AV			IOSTAR			CHASE-DB1		
	DICE	MCC	IoU	DICE	MCC	IoU	DICE	MCC	IoU
基础模型	0.735	0.713	0.581	0.669	0.640	0.502	0.663	0.639	0.496
加频带加权	0.740	0.718	0.587	0.675	0.647	0.509	0.671	0.648	0.505
加随机滤波	0.745	0.723	0.594	0.692	0.666	0.529	0.678	0.648	0.505
BIRF-SDG	0.787	0.770	0.649	0.747	0.731	0.597	0.729	0.709	0.574

从消融实验结果可以得出以下结论。通过频带加权机制，我们将图片解耦为对结构信息重要的频带和可以有效增强的频带，相比基础模型，添加频带加权后性能有小幅提升，LES-AV 的 DICE 从 0.735 提升到 0.740，说明该机制能够有效识别关键频带。通过频带随机滤波机制，我们对图像进行泛化并提高模型的泛化能力，添加随机滤波后，性能进一步提升，LES-AV 的 DICE 从 0.740 提升到 0.745，证明了随机滤波在增强数据多样性方面的有效性。完整模型（包含高频成分机制）在所有指标上都取得了最佳性能，特别是在 LES-AV 上，DICE 从 0.745 大幅提升到 0.787，说明高频成分机制对于保留血管结构至关重要。这三个模块的协同作用显著提高了模型在单源血管分割任务中的泛化能力，单独使用任一模块只能带来有限的提升，而组合使用则产生显著的协同效应。

图 10 展示了高频成分机制的可视化效果。通过高频滤波器提取的显著结构表示，模型能够更好地关注血管边界信息，从而提高分割精度。神经网络可视化技术如 Grad-CAM^[70] 可以进一步帮助我们理解模型的决策过程，而 ZFNet 的可视化方法^[71] 则揭示了卷积神经网络学习到的层次化特征。




图 12 高频成分机制可视化。第一列：原始眼底图像；第二列：通过高斯滤波提取的高频成分（HFC），突出显示了血管边缘和细节信息；第三列：高频解码器（HF Decoder）重建的高频特征，与真实高频成分高度相似；第四列：分割解码器（Seg Decoder）生成的最终分割结果。黄色箭头标注了高频成分与最终分割的对应关系，可以看到高频解码器有效提取的边界信息被分割解码器利用，从而提高了血管边界的分割精度。这种多流结构使模型能够显式地建模结构信息，增强了分割的准确性和连续性。

4.4 讨论

4.4.1 方法优势

BIRF-SDG 的主要优势在于四个方面。首先是自适应增强，与传统方法对所有频率成分进行同等处理不同，我们的方法能够自适应地识别关键频带，实现有选择性的增强。其次是结构保留，通过高频成分机制，我们能够在增强过程中保留血管的结构信息，避免了过度增强导致的性能下降。再次是无需目标域数据，与域适应方法不同，我们的方法在训练过程中不需要任何目标域数据，更符合实际应用场景。最后是计算效率高，频域操作可以通过快速傅里叶变换高效实现，不会显著增加训练时间。我们的方法可以很容易地部署到轻量级网络架构如 MobileNet^[72] 和 EfficientNet^[73] 上，适用于资源受限的医疗设备。

4.4.2 局限性

尽管 BIRF-SDG 取得了良好的性能，但仍存在以下局限性。频带划分的粒度方面，当前方法将频谱划分为固定的 10 个频带，可能无法捕获更细粒度的频率特征。超参数敏感

性方面，评分机制中的超参数 α 需要根据具体任务进行调整，缺乏自适应的调节机制。适用范围方面，当前方法主要针对视网膜血管分割任务，对于其他类型的医学图像分割任务，可能需要调整网络架构。此外，当前方法缺乏对预测不确定性的显式建模，贝叶斯深度学习方法^[74]可能有助于提高模型的可靠性。

4.4.3 未来改进方向

针对上述局限性，未来的研究可以从以下方向进行改进。自适应频带划分方面，探索基于数据驱动的自适应频带划分方法，而不是使用固定的均匀划分。超参数自适应方面，设计自适应的超参数调节机制，根据训练过程中的反馈动态调整 α 和 β 。扩展到其他任务方面，将方法扩展到其他医学图像分割任务，如肿瘤分割、器官分割等。结合其他增强技术方面，将频域增强与其他类型的增强技术（如混合增强、对抗增强）相结合，进一步提高泛化能力。

5. 结论

5.1 工作总结

本研究针对视网膜血管分割中的域偏移问题，提出了一种基于频带重要性感知的单源域泛化方法 BIRF-SDG。通过深入分析图像频域特征与分割性能之间的关系，我们设计了一套完整的框架，包括频带评分机制、随机滤波策略和多流分割网络。

本研究的主要理论贡献包括三个方面。首先是频带重要性感知机制，我们设计了一种评分机制，通过评估不同频率带对分割性能和结构信息保留的影响，自适应地识别关键频带。该机制基于以下观察：不同频率带对分割任务的贡献不同，结构相关频带需要特别保护，通过评分可以实现有选择性的增强。其次是加权随机频带滤波策略，基于频带评分，我们提出了一种加权随机滤波方法，仅对不影响结构信息的频带进行增强。这种策略的优势在于保留了关键的结构信息，增加了数据多样性，避免了过度增强导致的性能下降。再次是多流分割架构，我们设计了一个融合频域增强和分割任务的多流网络，通过高频解码器和分割解码器的协同工作，增强了模型对边界信息的感知能力。该架构的特点包括编码器-解码器结构提取多尺度特征，注意力机制促进信息交互，多任务学习提高特征质量。

通过在 LES-AV、IOSTAR 和 CHASE-DB1 等多个跨域数据集上的全面实验，我们验证了 BIRF-SDG 的有效性。在优越的性能方面，在所有测试数据集上，BIRF-SDG 都取得了最佳或接近最佳的性能，特别是在最具挑战性的 IOSTAR 数据集上，我们的方法显著优于现有方法。在良好的泛化能力方面，消融实验表明，各个模块的协同作用显著提高了模型的泛化能力，单独使用任一模块只能带来有限的提升，而组合使用则产生显著的协同效应。在可视化验证方面，定性分析显示，我们的方法能够更好地保持血管的连续性，检测到更多的细小血管，并有效地抑制噪声。

5.2 研究意义

本研究的理论意义体现在三个方面。首先是深化了对频域特征的理解，通过系统研究不同频率带对分割性能的影响，我们深化了对频域特征在医学图像分割中作用的理解，这为后续研究提供了理论基础。其次是提出了新的域泛化范式，传统的域泛化方法主要关注空间域的增强，而我们的方法从频域角度出发，提出了一种新的域泛化范式。再次是建立了频带评分框架，我们建立的频带评分框架可以推广到其他涉及频域分析的任务，具有广泛的适用性。

本研究的实际意义体现在四个方面。首先是降低数据依赖，与需要多源域数据的方法不同，我们的方法仅需单一源域数据即可实现有效的域泛化，大大降低了数据收集成本。这对于医疗领域尤为重要，因为获取多样化的医学图像数据往往面临隐私和成本的限制。其次是提高模型可靠性，通过显式地对频率带进行评分和选择，我们的方法提供了对模型决策过程的洞察，有助于理解模型的行为，提高了模型的可解释性和可靠性。再次是促进临床应用，我们的方法无需在部署时访问目标域数据，可以直接应用于新的医疗机构，促进了人工智能在眼科临床诊断中的实际应用。最后是通用性框架，虽然本研究聚焦于视网膜血管分割，但所提出的频带重要性感知机制可推广至其他医学图像分割任务，如肿瘤分割、器官分割等，为单源域泛化问题提供了一个通用的解决方案。

5.3 未来工作

尽管 BIRF-SDG 取得了良好的性能，仍有以下方向值得进一步探索。

方法改进方面包括三个方向。自适应频带划分方面，当前方法将频谱划分为固定的10个频带，可能无法捕获更细粒度的频率特征。未来可以探索基于数据驱动的自适应频带划分方法，根据数据的特性动态调整频带数量和边界。超参数自适应方面，评分机制中的超参数 α 和 β 需要根据具体任务进行调整。未来可以设计自适应的超参数调节机制，根据训练过程中的反馈动态调整这些参数。结合其他增强技术方面，将频域增强与其他类型的增强技术（如混合增强、对抗增强）相结合，可能进一步提高泛化能力。

应用扩展方面包括三个方向。扩展到其他医学图像模态方面，将方法扩展至其他医学图像模态，如 OCT（光学相干断层扫描）、超声图像、CT 和 MRI 等。不同模态的图像具有不同的频域特性，需要针对性地调整方法。应用到其他分割任务方面，将方法应用到其他医学图像分割任务，如皮肤病变分割、肺结节分割、细胞分割等，验证方法的通用性。结合自监督学习方面，结合自监督学习技术，利用未标注数据进一步提升模型的泛化能力。

理论深化方面包括三个方向。频域特征分析方面，深入研究不同医学图像的频域特性，建立更完善的频域特征分析理论。域偏移量化方面，开发更精确的域偏移量化方法，帮助理解不同域之间的差异。泛化边界分析方面，理论分析模型的泛化边界，为方法设计提供理论指导。

参考文献

References

- [1] GULSHAN V, PENG L, CORAM M, 等. Development and validation of a deep learning algorithm for detection of diabetic retinopathy in retinal fundus photographs[J]. jama, 2016, 316(22): 2402-2410.
- [2] ORLANDO J I, BARBOSA BREDA J, VAN KEER K, 等. Towards a glaucoma risk index based on simulated hemodynamics from fundus images[C]//Medical Image Computing and Computer Assisted Intervention–MICCAI 2018: 21st International Conference, Granada, Spain, September 16-20, 2018, Proceedings, Part II 11. 2018: 65-73.
- [3] GANIN Y, LEMPITSKY V. Unsupervised domain adaptation by backpropagation[C]//International Conference on Machine Learning. 2015: 1180-1189.
- [4] CUGU I, MANCINI M, CHEN Y, 等. Attention consistency on visual corruptions for single-source domain generalization[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 4165-4174.
- [5] OUYANG C, BIFFI C, RUECKERT D. Causality-inspired single-source domain generalization for medical image segmentation[J]. IEEE Transactions on Medical Imaging, 2023, 42(4): 1095-1106.
- [6] HU S, LIAO Z, ZHANG J, 等. Domain and content adaptive convolution based multi-source domain generalization for medical image segmentation[J]. IEEE Transactions on Medical Imaging, 2022, 42(1): 233-244.
- [7] XU Q, ZHANG R, ZHANG Y, 等. A fourier-based framework for domain generalization[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 14383-14392.
- [8] LI H, LI H, ZHAO W, 等. Frequency-mixed single-source domain generalization for medical image segmentation[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. 2023: 127-136.
- [9] STAAL J, ABRÀMOFF M D, NIEMEIJER M, 等. Ridge-based vessel segmentation in color images of the retina[J]. IEEE transactions on medical imaging, 2004, 23(4): 501-509.
- [10] LITJENS G, KOOI T, BEJNORDI B E, 等. A survey on deep learning in medical image analysis[J]. Medical Image Analysis, 2017, 42: 60-88.

- [11] HESAMIAN M H, JIA W, HE X, 等. Deep learning techniques for medical image segmentation: Achievements and challenges[J]. Journal of Digital Imaging, 2019, 32: 582-596.
- [12] OKTAY O, SCHLEMPER J, FOLGOC L L, 等. Attention U-Net: Learning where to look for the pancreas[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. 2018: 304-312.
- [13] HUANG G, LIU Z, VAN DER MAATEN L, 等. Densely connected convolutional networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 4700-4708.
- [14] HE K, ZHANG X, REN S, 等. Deep residual learning for image recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770-778.
- [15] BADRINARAYANAN V, KENDALL A, CIPOLLA R. SegNet: A deep convolutional encoder-decoder architecture for image segmentation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(12): 2481-2495.
- [16] CHEN L C, PAPANDREOU G, KOKKINOS I, 等. DeepLab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected CRFs[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 40(4): 834-848.
- [17] ZHAO H, SHI J, QI X, 等. Pyramid scene parsing network[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 2881-2890.
- [18] CHEN L C, ZHU Y, PAPANDREOU G, 等. Encoder-decoder with atrous separable convolution for semantic image segmentation[C]//Proceedings of the European Conference on Computer Vision. 2018: 801-818.
- [19] HU J, SHEN L, SUN G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 7132-7141.
- [20] WANG Q, WU B, ZHU P, 等. ECA-Net: Efficient channel attention for deep convolutional neural networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 11534-11542.
- [21] DOU Q, CASTRO D Coelho de, KAMNITSAS K, 等. Domain generalization via model-agnostic learning of semantic features[C]//Advances in Neural Information Processing Systems: 卷 32. 2019.
- [22] LI H, PAN S J, WANG S, 等. Domain generalization with adversarial feature learning[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 5400-5409.
- [23] GOODFELLOW I, POUGET-ABADIE J, MIRZA M, 等. Generative adversarial nets[C]//Advances in Neural Information Processing Systems: 卷 27. 2014.

- [24] ISOLA P, ZHU J Y, ZHOU T, 等. Image-to-image translation with conditional adversarial networks[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 1125-1134.
- [25] OUYANG C, CHEN C, LI S, 等. Causality-inspired single-source domain generalization for medical image segmentation[J]. IEEE Transactions on Medical Imaging, 2022, 42(4): 1095-1106.
- [26] ZHANG H, CISSE M, DAUPHIN Y N, 等. mixup: Beyond empirical risk minimization[C]// International Conference on Learning Representations. 2018.
- [27] YUN S, HAN D, OH S J, 等. CutMix: Regularization strategy to train strong classifiers with localizable features[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 6023-6032.
- [28] CUBUK E D, ZOPH B, MANE D, 等. AutoAugment: Learning augmentation policies from data[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2019: 113-123.
- [29] INOUE H. Multi-sample dropout for accelerated training and better generalization[J]. arXiv preprint arXiv:1905.09788, 2019.
- [30] HENDRYCKS D, MU N, CUBUK E D, 等. AugMix: A simple data processing method to improve robustness and uncertainty[C]//International Conference on Learning Representations. 2020.
- [31] FINN C, ABBEEL P, LEVINE S. Model-agnostic meta-learning for fast adaptation of deep networks[C]//International Conference on Machine Learning. 2017: 1126-1135.
- [32] NICHOL A, ACHIAM J, SCHULMAN J. On first-order meta-learning algorithms[C]//arXiv preprint arXiv:1803.02999. 2018.
- [33] MCMAHAN B, MOORE E, RAMAGE D, 等. Communication-efficient learning of deep networks from decentralized data[C]//Artificial Intelligence and Statistics. 2017: 1273-1282.
- [34] NITISH S. Dropout: a simple way to prevent neural networks from overfitting[J]. J. Mach. Learn. Res., 2014, 15: 1.
- [35] ZHANG J, DASHTBOZORG B, BEKKERS E, 等. Robust retinal vessel segmentation via locally adaptive derivative frames in orientation scores[J]. IEEE transactions on medical imaging, 2016, 35(12): 2631-2644.
- [36] YANG Y, SOATTO S. FDA: Fourier domain adaptation for semantic segmentation[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2020: 4085-4095.
- [37] CHI L, JIANG B, YE M. Fast Fourier convolution[C]//Advances in Neural Information Processing Systems: 卷 33. 2020: 4479-4488.

- [38] QIN Z, ZHANG P, WU F, 等. FcaNet: Frequency channel attention networks[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 783-792.
- [39] LI B, LI H, ZHANG Y, 等. FD-SDG: Frequency Dropout Based Single Source Domain Generalization Framework for Retinal Vessel Segmentation[C]//International Conference on Intelligent Computing. 2024: 393-404.
- [40] LI H, LI H, CHEN J, 等. RaffeSDG: random frequency filtering enabled single-source domain generalization for medical image segmentation[J]. arXiv preprint arXiv:2405.01228, 2024.
- [41] LI H, LI H, SHU H, 等. Self-supervision boosted retinal vessel segmentation for cross-domain data[C]//2023 IEEE 20th International Symposium on Biomedical Imaging (ISBI). 2023: 1-5.
- [42] SU Z, YAO K, YANG X, 等. Rethinking data augmentation for single-source domain generalization in medical image segmentation[C]//Proceedings of the AAAI conference on artificial intelligence: 卷 37. 2023: 2366-2374.
- [43] LI H, LIU H, FU H, 等. A generic fundus image enhancement network boosted by frequency self-supervised representation learning[J]. Medical Image Analysis, 2023, 90: 102945.
- [44] LI H, LIN Z, QIU Z, 等. Enhancing and adapting in the clinic: source-free unsupervised domain adaptation for medical image enhancement[J]. IEEE Transactions on Medical Imaging, 2023, 43(4): 1323-1336.
- [45] SHU X, WANG J, ZHANG A, 等. CSCA U-Net: A channel and space compound attention CNN for medical image segmentation[J]. Artificial Intelligence in Medicine, 2024, 150: 102800.
- [46] LIU Q, CHEN C, QIN J, 等. Feddg: Federated domain generalization on medical image segmentation via episodic learning in continuous frequency space[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 1013-1023.
- [47] ZHAO L, WANG L. Task-specific inconsistency alignment for domain adaptive object detection[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 14217-14226.
- [48] WOO S, PARK J, LEE J Y, 等. Cbam: Convolutional block attention module[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.
- [49] OWEN C G, RUDNICKA A R, NIGHTINGALE C M, 等. Retinal arteriolar tortuosity and cardiovascular risk factors in a multi-ethnic population study of 10-year-old children; the Child Heart

- and Health Study in England (CHASE)[J]. *Arteriosclerosis, thrombosis, and vascular biology*, 2011, 31(8): 1933-1938.
- [50] ZHANG W, DING X, LIU Y, 等. Slide deep reinforcement learning networks: Application for left ventricle segmentation[J]. *Pattern Recognition*, 2023, 141: 109667.
- [51] ZHANG W, LI S, WANG Y, 等. EEMSNet: Eagle-Eye Multi-Scale Supervised Network for cardiac segmentation[J]. *Biomedical Signal Processing and Control*, 2024, 96: 106638.
- [52] ESTEVA A, KUPREL B, NOVOA R A, 等. Dermatologist-level classification of skin cancer with deep neural networks[J]. *Nature*, 2017, 542(7639): 115-118.
- [53] RAJPURKAR P, IRVIN J, ZHU K, 等. CheXNet: Radiologist-level pneumonia detection on chest X-rays with deep learning[J]. *arXiv preprint arXiv:1711.05225*, 2017.
- [54] OU M, LI H, LIU H, 等. MVD-Net: Semantic segmentation of cataract surgery using multi-view learning[C]//2022 44th Annual International Conference of the IEEE Engineering in Medicine & Biology Society (EMBC). 2022: 5035-5038.
- [55] LI H, LI H, CHEN J, 等. Aif-sfda: Autonomous information filter-driven source-free domain adaptation for medical image segmentation[J]. *arXiv preprint arXiv:2501.03074*, 2025.
- [56] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, 等. An image is worth 16x16 words: Transformers for image recognition at scale[C]//International Conference on Learning Representations. 2021.
- [57] LIU Z, WANG Y, VAIDYA S, 等. KAN: Kolmogorov-Arnold Networks[C]. 2024.
- [58] HE K, FAN H, WU Y, 等. Momentum contrast for unsupervised visual representation learning[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 9729-9738.
- [59] CHEN T, KORNBLITH S, NOROUZI M, 等. A simple framework for contrastive learning of visual representations[C]//International Conference on Machine Learning. 2020: 1597-1607.
- [60] HINTON G E, SRIVASTAVA N, KRIZHEVSKY A, 等. Improving neural networks by preventing co-adaptation of feature detectors[J]. *arXiv preprint arXiv:1207.0580*, 2012.
- [61] LIN T Y, GOYAL P, GIRSHICK R, 等. Focal loss for dense object detection[C]//Proceedings of the IEEE International Conference on Computer Vision. 2017: 2980-2988.
- [62] DOBADO A, PELAEZ J. Inverse amplitude method in chiral perturbation theory[J]. *Physical Review D*, 1997, 56(5): 3057.
- [63] LI H, LI H, QIU Z, 等. Domain adaptive retinal vessel segmentation guided by high-frequency component[C]//International Workshop on Ophthalmic Medical Image Analysis. 2022: 115-124.

- [64] VASWANI A, SHAZEER N, PARMAR N, 等. Attention is all you need[C]//Advances in Neural Information Processing Systems: 卷 30. 2017.
- [65] WANG X, GIRSHICK R, GUPTA A, 等. Non-local neural networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 7794-7803.
- [66] TING D S, CHEUNG C Y, LIM G, 等. Development and validation of a deep learning system for diabetic retinopathy and related eye diseases using retinal images from multiethnic populations with diabetes[J]. JAMA, 2017, 318(22): 2211-2223.
- [67] KINGMA D P, BA J. Adam: A method for stochastic optimization[C]//International Conference on Learning Representations. 2015.
- [68] LIU Q, YU L, CHEN P A, 等. Do we really need that many samples? A diagnostic study of sample diversity in medical image analysis[J]. Medical Image Analysis, 2022, 76: 102313.
- [69] LOSHCHILOV I, HUTTER F. Decoupled weight decay regularization[C]//International Conference on Learning Representations. 2019.
- [70] SELVARAJU R R, COGSWELL M, DAS A, 等. Grad-CAM: Visual explanations from deep networks via gradient-based localization[C]//Proceedings of the IEEE International Conference on Computer Vision. 2017: 618-626.
- [71] ZEILER M D, FERGUS R. Visualizing and understanding convolutional networks[C]//European Conference on Computer Vision. 2014: 818-833.
- [72] HOWARD A G, ZHU M, CHEN B, 等. MobileNets: Efficient convolutional neural networks for mobile vision applications[C]//arXiv preprint arXiv:1704.04861. 2017.
- [73] TAN M, LE Q. EfficientNet: Rethinking model scaling for convolutional neural networks[C]//International Conference on Machine Learning. 2019: 6105-6114.
- [74] KENDALL A, GAL Y. What uncertainties do we need in Bayesian deep learning for computer vision? [C]//Advances in Neural Information Processing Systems: 卷 30. 2017.

致谢

Acknowledgements

首先,我要衷心感谢我的导师刘江教授。从论文选题到实验设计,从理论推导到论文撰写,刘老师始终给予我悉心的指导和宝贵的建议。刘老师严谨的治学态度、深厚的学术造诣和对学生无私的关怀,让我受益匪浅,这将是我未来学术道路上的宝贵财富。感谢课题组的所有老师和同学们。特别感谢实验室的师兄师姐们在研究过程中给予的帮助和指导,感谢同门们在讨论中提供的启发和建议。与大家的交流让我开阔了视野,也收获了珍贵的友谊。感谢南方科技大学计算机科学与工程系提供的优质学习环境和科研资源。感谢学校图书馆和计算中心提供的便利条件,为本研究的顺利开展提供了有力保障。最后,我要特别感谢我自己。感谢自己在面对困难时的坚持,在无数个深夜里调试代码、修改论文的付出。感谢自己保持对科研的热情,不断学习和探索。这段毕设经历让我成长了许多,也让我更加坚定了未来的方向。再次感谢所有帮助过我的人!